MAESTRÍA EN ESTADÍSTICA

Asignatura: Redes Neuronales y Deep Learning

COMPARACIÓN DE MODELOS DE APRENDIZAJE AUTOMÁTICO PARA LA PREDICCIÓN DE ALERTAS DE INUNDACIÓN MEDIANTE VARIABLES HIDROMETEOROLÓGICAS

Docente:

Ing. Edwin Mejía

Integrantes:

Wilson Sani

William Allauca

Carlos Cuenca

Gustavo Chaglla

Fecha: Noviembre de 2026

1. Introducción

Las inundaciones figuran entre los fenómenos hidrometeorológicos de mayor impacto social y económico, y su gestión descansa cada vez más en sistemas de alerta temprana que transforman mediciones de precipitación, caudal, nivel de los cauces y humedad del suelo en decisiones operativas. En esos sistemas, la pregunta central no es cuánto lloverá ni qué caudal se alcanzará, sino si las condiciones observadas justifican declarar un estado de alerta. Formulada así, la tarea corresponde a un problema de clasificación binaria: a partir de un vector de variables hidrometeorológicas y territoriales se busca estimar la probabilidad de que una estación se encuentre en condición de inundación y, con base en un umbral, asignarla a la clase de alerta o a la clase normal.

Los modelos de clasificación supervisada ofrecen un marco natural para esta tarea. La regresión logística constituye la referencia clásica porque modela de forma explícita el logaritmo de las odds del evento y produce probabilidades con fundamento verosimilístico. Los métodos basados en árboles, como los árboles de decisión, Random Forest y XGBoost, permiten capturar umbrales, interacciones y no linealidades sin especificarlas de antemano; las máquinas de vectores de soporte construyen fronteras de máximo margen en espacios transformados mediante núcleos, y el método de los k vecinos más cercanos clasifica por analogía con observaciones similares. Cada familia responde a supuestos distintos sobre la forma de la relación entre predictores y respuesta, de modo que su comparación empírica aporta información sobre la estructura del problema y no únicamente sobre el algoritmo con mejor puntaje.

La comparación exige, sin embargo, una evaluación estadística cuidadosa. En un sistema de alerta los errores no tienen el mismo costo: omitir una inundación real (falso negativo) suele ser más grave que emitir una falsa alarma (falso positivo), aunque una tasa elevada de falsas alarmas erosiona la credibilidad del sistema. Por ello la exactitud global resulta insuficiente como criterio único. Es necesario examinar la sensibilidad y la especificidad, la capacidad discriminante resumida por el área bajo la curva ROC, la calidad de las probabilidades estimadas mediante Log Loss y Brier Score, y la diferencia entre el desempeño en entrenamiento y en datos no vistos, que revela sobreajuste. También es necesario distinguir entre diferencias observadas en una muestra de prueba finita y diferencias estadísticamente demostradas.

El problema de investigación que aborda este trabajo es determinar cómo se comparan seis clasificadores supervisados de uso extendido (regresión logística, árbol de decisión, Random Forest, XGBoost, máquina de vectores de soporte y k vecinos más cercanos) cuando se aplican, bajo un protocolo común, a la predicción del estado de alerta por inundación a partir de nueve variables hidrometeorológicas y territoriales. La justificación es doble. En el plano metodológico, el ejercicio permite contrastar modelos de distinta complejidad con un conjunto homogéneo de métricas y pruebas, y documentar las consecuencias del umbral de decisión y de la ponderación de clases. En el plano aplicado, ilustra los criterios con los que debería seleccionarse un modelo para un sistema de alerta, donde la elección depende del uso que se dará a las predicciones.

El análisis se desarrolló en una aplicación R Shiny elaborada por el equipo, que integra la carga de datos, el análisis exploratorio, la preparación, el entrenamiento de los seis modelos, la comparación, la interpretación, un laboratorio de sobreajuste y un módulo de predicción. El alcance del estudio es académico. La base de datos utilizada es sintética: reproduce variables con nombres, unidades y rangos plausibles, pero no corresponde a observaciones de una red de estaciones real. En consecuencia, los resultados permiten comparar el comportamiento de los métodos en un escenario controlado, pero no deben interpretarse como evidencia de capacidad predictiva operativa sobre una cuenca o territorio concreto, para lo cual sería indispensable una validación externa con registros hidrometeorológicos reales.

2. Objetivos

2.1. Objetivo general

Comparar el desempeño predictivo de seis modelos de clasificación supervisada (regresión logística, árbol de decisión, Random Forest, XGBoost, máquina de vectores de soporte y k vecinos más cercanos) para la identificación de alertas de inundación mediante variables hidrometeorológicas, empleando métricas estadísticas de discriminación, clasificación y calidad probabilística evaluadas sobre datos no utilizados en el ajuste.

2.2. Objetivos específicos

a) Caracterizar la base de datos mediante estadística descriptiva, análisis de valores faltantes, distribución de la variable objetivo y pruebas de asociación entre cada predictor y el estado de alerta.

b) Preparar los datos para el modelado mediante imputación, codificación de variables categóricas, estandarización y partición estratificada en conjuntos de entrenamiento y prueba, controlando la fuga de información.

c) Entrenar los seis modelos con una misma partición, semilla aleatoria y esquema de ponderación de clases, documentando los hiperparámetros utilizados.

d) Evaluar comparativamente los modelos con nueve métricas (Accuracy, Precision, Recall, especificidad, F1, MCC, AUC, Log Loss y Brier Score), matrices de confusión, curvas ROC, validación cruzada y pruebas estadísticas de comparación.

e) Diagnosticar sobreajuste y subajuste comparando el desempeño en entrenamiento y en prueba y analizando curvas de complejidad.

f) Identificar los modelos con mejor desempeño según cada criterio, las variables con mayor contribución predictiva y el efecto del umbral de clasificación sobre el equilibrio entre sensibilidad y falsas alarmas.

3. Materiales y métodos

3.1. Naturaleza y procedencia de los datos

Se utilizó el archivo datos_control_inundaciones.xlsx, cuya hoja Datos_Inundaciones contiene 1.200 registros y 11 variables; una segunda hoja, Resumen_Indicadores, contiene fórmulas de resumen que no intervienen en el análisis. La unidad de análisis es el registro de una estación de monitoreo, identificado por un código único (EST-0001 a EST-1200), al que se asocian una zona hidrológica, siete mediciones hidrometeorológicas o de manejo y el estado de alerta. Cada registro se trata como una observación independiente; la base no contiene marcas de tiempo ni coordenadas, por lo que no es posible modelar dependencia temporal o espacial.

La base es sintética. Tres elementos sustentan esta afirmación: los metadatos del libro indican que fue generado por programa (biblioteca openpyxl) y no documentan una red de estaciones, fechas ni fuente observacional; el código de la aplicación (app.R) incluye una función generadora con exactamente las mismas variables, en la que la probabilidad del evento se define mediante un predictor lineal logístico; y las correlaciones entre variables físicamente vinculadas, como precipitación, caudal y nivel del río, son prácticamente nulas ($|r| \leq 0{,}04$), algo atípico en series hidrológicas reales. El archivo analizado no coincide registro a registro con la salida de esa función (por ejemplo, el número de faltantes por variable difiere), por lo que no

puede afirmarse que el mecanismo generador sea idéntico; sí puede afirmarse que se trata de datos simulados con fines didácticos. La Tabla 1 describe las variables.

Tabla 1

Variables de la base de datos

Variable	Tipo	Unidad o niveles	Rol	Faltantes
id_estacion	Texto	EST-0001 a EST-1200	Identificador (excluido)	0
zona_hidrologica	Categórica nominal	Cuenca Alta, Cuenca Media, Valle Bajo, Zona Urbana Costera	Predictor	0
precipitacion_mm	Cuantitativa continua	mm	Predictor	12
caudal_m3_s	Cuantitativa continua	m^3/s	Predictor	9
nivel_rio_m	Cuantitativa continua	m	Predictor	11
saturacion_suelo_pct	Cuantitativa continua	% (10–100)	Predictor	9
cobertura_vegetal_pct	Cuantitativa continua	%	Predictor	0
temperatura_C	Cuantitativa continua	°C	Predictor	0
humedad_relativa_pct	Cuantitativa continua	% (hasta 100)	Predictor	0
mantenimiento_canales	Cuantitativa discreta (conteo)	Número de intervenciones (0–8)	Predictor	0
estado_alerta	Categórica binaria	Inundacion, Normal	Respuesta	0

Nota. Elaboración propia a partir de datos_control_inundaciones.xlsx. En total existen 41 celdas faltantes, el 0,31 % de las 13.200 celdas de la base.

3.2. Variable dependiente y distribución de clases

La variable dependiente es estado_alerta, con dos categorías. Se definió como clase positiva la categoría Inundacion, de modo que $Y = 1$ indica alerta por inundación y $Y = 0$ condición normal. La base contiene 701 registros positivos (58,4 %) y 499 negativos (41,6 %). El desbalance es moderado, pero suficiente para que un clasificador trivial que asigne siempre la clase positiva alcance una exactitud cercana al 58 %, valor que se utiliza como tasa de referencia al interpretar las métricas.

3.3. Análisis estadístico exploratorio

Para cada variable numérica se calcularon tamaño muestral efectivo, media, desviación estándar, mínimo, cuartiles, máximo, coeficiente de asimetría y curtosis en exceso. La asociación de cada predictor con el estado de alerta se evaluó con la prueba *t* de Welch, que no supone igualdad de varianzas, complementada con la prueba de Wilcoxon-Mann-Whitney

como alternativa no paramétrica; para la zona hidrológica se aplicó la prueba ji cuadrado de independencia. La magnitud de la asociación se cuantificó con la *d* de Cohen, orientada de forma que valores positivos indican medias mayores en la clase Inundación, y con la *V* de Cramér para la variable categórica:

$$d = \frac{\bar{x}_1 - \bar{x}_0}{s_p}, \quad s_p = \sqrt{\frac{(n_1-1)s_1^2 + (n_0-1)s_0^2}{n_1+n_0-2}} \tag{1}$$

donde los subíndices 1 y 0 identifican las clases Inundación y Normal. Los valores *p* se ajustaron por comparaciones múltiples con el procedimiento de Benjamini-Hochberg, que controla la tasa de falsos descubrimientos, y se consideró significativa una asociación con *p* ajustado inferior a 0,05. La dependencia lineal entre predictores numéricos se examinó con la matriz de correlaciones de Pearson calculada con pares completos.

3.4. Preparación de los datos

Se descartaron los registros con variable objetivo faltante (no hubo ninguno) y se excluyó id_estacion de los predictores. Los valores faltantes de las variables numéricas se imputaron con la mediana y los de las categóricas con la moda. En la implementación de la aplicación estos valores de referencia se calculan sobre la base completa antes de la partición; las medianas resultantes fueron 45,685 mm para precipitación, 120,77 m³/s para caudal, 3,16 m para nivel del río y 64,6 % para saturación del suelo. Este procedimiento introduce una fuga de información mínima, porque los datos de prueba contribuyen a la mediana utilizada para imputar, pero su alcance se limita a 41 celdas, el 0,38 % de la matriz de predictores.

La zona hidrológica se codificó mediante variables indicadoras con codificación de tratamiento, tomando Cuenca Alta como categoría de referencia, lo que generó tres columnas (Cuenca Media, Valle Bajo y Zona Urbana Costera) y una matriz de diseño de 11 columnas. Para los modelos sensibles a la escala (regresión logística, SVM y KNN) cada columna se estandarizó con la media y la desviación estándar del conjunto de entrenamiento,

$$z_{ij} = \frac{x_{ij} - \bar{x}_j^{(train)}}{s_j^{(train)}} \tag{2}$$

de forma que la transformación aplicada a los datos de prueba y a los datos nuevos usa exclusivamente parámetros estimados en entrenamiento. El árbol de decisión, Random Forest y XGBoost se ajustaron en la escala original, lo que preserva la legibilidad de los umbrales de partición.

La partición fue estratificada por clase con una proporción de prueba de 0,20 y semilla aleatoria 2024: dentro de cada clase se seleccionó aleatoriamente el 80 % de los registros para entrenamiento, lo que produjo 960 registros de entrenamiento (561 positivos y 399 negativos) y 240 de prueba (140 positivos y 100 negativos). Para compensar el desbalance se asignaron pesos de clase inversamente proporcionales a la frecuencia en entrenamiento,

$$w_c = \frac{n}{2n_c}, \quad w_1 = \frac{960}{2 \cdot 561} = 0{,}856, \quad w_0 = \frac{960}{2 \cdot 399} = 1{,}203 \tag{3}$$

que se incorporaron como pesos de observación en la regresión logística y el árbol, como pesos de clase en Random Forest y SVM, y mediante el parámetro scale_pos_weight = 399/561 = 0,711 en XGBoost. El método KNN no admite ponderación en la implementación utilizada.

3.5. Modelos de clasificación

Los seis modelos estiman, a partir del vector de predictores x, una probabilidad $\hat{p}(x) = \hat{P}(Y = 1 \mid x)$, y la clase se asigna mediante la regla $\hat{Y} = 1$ si $\hat{p}(x) \geq \tau$, con $\tau = 0{,}5$ salvo cuando se analiza explícitamente el efecto del umbral.

3.5.1. Regresión logística

La regresión logística modela el logit de la probabilidad como función lineal de los predictores estandarizados:

$$logit\ p(x) = ln \frac{p(x)}{1-p(x)} = \beta_0 + \sum_{j=1}^{11} \beta_j z_j \tag{4}$$

Los coeficientes se estimaron por máxima verosimilitud ponderada, maximizando

$$\ell(\beta) = \sum_{i=1}^{n} w_i [y_i\ ln\ p_i + (1 - y_i)\ ln(1 - p_i)] \tag{5}$$

mediante la función glm de R con familia binomial. Al estar estandarizados los predictores, $\exp(\beta j)$ se interpreta como el odds ratio asociado a un aumento de una desviación estándar en la variable j, manteniendo constantes las demás. Dado que los pesos no son frecuencias, los errores estándar y valores p que reporta glm son aproximados.

3.5.2. Árbol de decisión

El árbol de clasificación (algoritmo CART, paquete rpart) particiona recursivamente el espacio de predictores mediante divisiones binarias del tipo $xj < c$, eligiendo en cada nodo la división que maximiza la reducción ponderada de la impureza de Gini,

$$G(t) = 1 - \sum_{k \in \{0,1\}} p_k^2(t) \tag{6}$$

donde *pk*(*t*) es la proporción ponderada de la clase *k* en el nodo *t*. El crecimiento se limitó con profundidad máxima 4, parámetro de complejidad cp = 0,01 (una división se conserva solo si reduce el error relativo al menos en 1 %) y un mínimo de 20 casos para intentar una división; no se usó validación cruzada interna (xval = 0). La probabilidad asignada a un caso es la proporción ponderada de positivos en su hoja.

3.5.3. Random Forest

Random Forest (paquete randomForest) promedia *B* árboles de clasificación crecidos sobre muestras bootstrap del entrenamiento; en cada división se considera un subconjunto aleatorio de mtry predictores, lo que reduce la correlación entre árboles y, con ella, la varianza del ensamble. La probabilidad estimada es la proporción de votos:

$$\hat{p}(x) = \frac{1}{B}\sum_{b=1}^{B} I(T_b(x) = 1) \tag{7}$$

Se utilizaron *B* = 300 árboles, mtry = 3, tamaño mínimo de nodo terminal igual a 5 y pesos de clase. Las observaciones no incluidas en cada muestra bootstrap (out-of-bag, OOB) proporcionan una estimación interna del error de generalización.

3.5.4. XGBoost

XGBoost (paquete xgboost) construye un modelo aditivo de *K* árboles, $F(x) = \Sigma\, fk(x)$, ajustados secuencialmente mediante boosting por gradiente de segundo orden. Cada árbol nuevo minimiza la aproximación de Taylor de la función objetivo regularizada,

$$\mathcal{L} = \sum_{i=1}^{n} l(y_i, \hat{y}_i) + \sum_{k=1}^{K} \Omega(f_k)\,, \;\; \Omega(f) = \gamma T + \frac{1}{2}\lambda \|w\|^2 \tag{8}$$

donde *l* es la log-pérdida binomial, *T* el número de hojas y *w* el vector de pesos de las hojas. Se emplearon 150 rondas, profundidad máxima 3, tasa de aprendizaje η = 0,05, submuestreo de filas 0,8, submuestreo de columnas por árbol 0,8 y scale_pos_weight = 0,711, con los valores por defecto del paquete para γ y λ. La probabilidad se obtiene como $\hat{p}(x) = 1/(1 + \exp(-F(x)))$.

3.5.5. Máquina de vectores de soporte

La SVM (paquete e1071, basado en LIBSVM) busca el hiperplano de máximo margen en el espacio inducido por un núcleo, admitiendo violaciones del margen penalizadas por el costo *C*. Se utilizó el núcleo radial

$$K(x, x') = exp(-\gamma \|x - x'\|^2) \tag{9}$$

con $C = 1$ y $\gamma = 0{,}1$ sobre los 11 predictores estandarizados y con pesos de clase. Como la SVM produce una función de decisión $f(x)$ y no una probabilidad, esta se estimó mediante el escalamiento de Platt,

$$P(Y = 1 \mid x) = \frac{1}{1+exp(A\, f(x)+B)} \tag{10}$$

cuyos parámetros A y B se ajustan con validación cruzada interna. En consecuencia, la clase asignada con $\tau = 0{,}5$ se basa en esta probabilidad y no directamente en el signo de $f(x)$.

3.5.6. K vecinos más cercanos

KNN (función knn del paquete class) asigna a cada caso la proporción de positivos entre sus k vecinos más cercanos según la distancia euclídea en el espacio estandarizado,

$$\hat{p}(x) = \frac{1}{k}\sum_{i \in N_k(x)} I(y_i = 1) \tag{11}$$

con $k = 15$. Las probabilidades resultantes son múltiplos de 1/15 y el método, al carecer de ponderación de clases, hereda la proporción de la clase mayoritaria en las vecindades.

3.6. Hiperparámetros y procedimiento de entrenamiento

Todos los modelos se ajustaron sobre los mismos 960 registros de entrenamiento, fijando la semilla 2024 antes de cada ajuste para garantizar reproducibilidad en los componentes aleatorios (muestras bootstrap, submuestreo y validación interna de Platt). Los hiperparámetros corresponden a los valores por defecto de la aplicación y se resumen en la Tabla 2; no se realizó búsqueda sistemática de hiperparámetros, por lo que los resultados deben entenderse como el desempeño de configuraciones razonables y no de configuraciones optimizadas.

Tabla 2

Hiperparámetros y tratamiento de los datos por modelo

Modelo	Hiperparámetros	Escala	Ponderación
Regresión logística	glm binomial; sin hiperparámetros de ajuste	Estandarizada	Pesos de observación
Árbol de decisión	maxdepth = 4; cp = 0,01; minsplit = 20; xval = 0	Original	Pesos de observación
Random Forest	ntree = 300; mtry = 3; nodesize = 5	Original	classwt
XGBoost	nrounds = 150; max_depth = 3; η = 0,05; subsample = 0,8; colsample_bytree = 0,8	Original	scale_pos_weight = 0,711
SVM	Núcleo radial; C = 1; γ = 0,1; probability = TRUE	Estandarizada	class.weights
KNN	k = 15; distancia euclídea; probabilidad = proporción de votos	Estandarizada	No aplica

Nota. Valores por defecto de los módulos 3 y 4 de la aplicación. Semilla 2024; proporción de prueba 0,20; opción «Balancear clases con pesos» activada.

3.7. Métricas de evaluación

Sea VP, FN, FP y VN el número de verdaderos positivos, falsos negativos, falsos positivos y verdaderos negativos en el conjunto de prueba con el umbral τ. Las métricas dependientes del umbral se definieron como:

$$Accuracy = \frac{VP+VN}{n}, \quad Precision = \frac{VP}{VP+FP} \tag{12}$$

$$Recall = \frac{VP}{VP+FN}, \quad Especificidad = \frac{VN}{VN+FP} \tag{13}$$

$$F_1 = \frac{2 \cdot Precision \cdot Recall}{Precision+Recall} \tag{14}$$

$$MCC = \frac{VP \cdot VN - FP \cdot FN}{\sqrt{(VP+FP)(VP+FN)(VN+FP)(VN+FN)}} \tag{15}$$

El coeficiente de correlación de Matthews (MCC) es la correlación de Pearson entre la clase observada y la predicha; utiliza las cuatro celdas de la matriz de confusión y no se infla con el desbalance, a diferencia de la exactitud y del F1. Las métricas independientes del umbral fueron:

$$AUC = P(\hat{p}_i > \hat{p}_j \mid y_i = 1, y_j = 0) \tag{16}$$

$$LogLoss = -\frac{1}{n}\sum_{i=1}^{n}[y_i \, ln \, \hat{p}_i + (1 - y_i) \, ln(1 - \hat{p}_i)] \tag{17}$$

$$Brier = \frac{1}{n}\sum_{i=1}^{n}(\hat{p}_i - y_i)^2 \tag{18}$$

El AUC es la probabilidad de que un caso positivo elegido al azar reciba una probabilidad mayor que un caso negativo elegido al azar, y se calculó con el paquete pROC; mide discriminación, es decir, capacidad de ordenar los casos. El Log Loss, en el que las probabilidades se acotaron al intervalo $[10^{-7}, 1 - 10^{-7}]$, y el Brier Score son reglas de puntuación propias que penalizan probabilidades alejadas del resultado observado; combinan discriminación y calibración, por lo que un valor menor no implica por sí solo una mejor calibración. La calibración se examinó complementariamente con curvas de confiabilidad por deciles de probabilidad predicha.

3.8. Validación, diagnóstico de sobreajuste y comparaciones estadísticas

La evaluación principal se realizó en el conjunto de prueba, que no intervino en ningún ajuste. Como complemento se ejecutó la validación cruzada estratificada de cinco pliegues que ofrece la aplicación (opción desactivada por defecto), calculada exclusivamente sobre los 960 registros de entrenamiento con la misma semilla e hiperparámetros, y se registró el AUC de cada pliegue. El sobreajuste se diagnosticó con la diferencia entre el AUC de entrenamiento y

el de prueba (brecha) y con el laboratorio de complejidad de la aplicación, que reentrena el árbol con profundidades de 1 a 12 (cp = 0,001, minsplit = 10), KNN con *k* impar de 1 a 45 y XGBoost con 10 a 190 rondas, registrando el AUC en ambos conjuntos.

Para distinguir diferencias observadas de diferencias estadísticamente sustentadas se aplicaron tres procedimientos sobre las predicciones de prueba, que son pareadas porque todos los modelos evalúan los mismos 240 casos: la prueba de DeLong para comparar AUC correlacionados, junto con intervalos de confianza al 95 % del AUC por el mismo método; la prueba exacta de McNemar para comparar exactitudes, basada en los casos discordantes; y un intervalo bootstrap percentil (5.000 remuestreos) para la diferencia de exactitud entre los dos modelos más destacados. Los valores *p* de las comparaciones múltiples se ajustaron con el método de Holm. Estos análisis no forman parte de la interfaz de la aplicación y se presentan identificados como análisis complementarios.

3.9. Herramientas computacionales y verificación de los resultados

La aplicación se desarrolló en R con los paquetes shiny, readxl, dplyr, ggplot2, plotly, pROC, rpart, rpart.plot, randomForest, e1071, class y xgboost. La aplicación publicada (https://wilson17.shinyapps.io/ML_CLASICO_INUNDACIONES/) no pudo consultarse mediante herramientas automatizadas, porque el servidor restringe ese tipo de acceso y sus resultados se generan de forma interactiva. Por ello, los resultados de este informe se obtuvieron ejecutando el código original app.R con la misma base de datos y los parámetros por defecto, en R 4.3.3 con randomForest 4.7-1.1, rpart 4.1.23, e1071 1.7-14, class 7.3-22, xgboost 3.2.1.1 y pROC 1.18.5. La ejecución reprodujo exactamente las 24 cifras de referencia registradas en una ejecución previa de la aplicación publicada (Accuracy, Recall, AUC y F1 de los seis modelos), lo que respalda la correspondencia entre ambas fuentes. Las métricas restantes, las matrices de confusión, los resultados del laboratorio y los análisis complementarios proceden de la misma ejecución y coinciden con los presentados en la presentación Comparacion_ML_Alertas_Inundacion.pptx. Si la aplicación publicada se ejecutara con versiones de paquetes distintas, podrían aparecer variaciones menores en los modelos con componentes aleatorios.

4. Resultados

4.1. Caracterización de la base de datos

La base analizada contiene 1.200 registros y 11 variables: un identificador, una variable categórica de cuatro niveles (zona hidrológica), siete variables cuantitativas continuas, una variable de conteo y la variable objetivo binaria. Se identificaron 41 valores faltantes, concentrados en cuatro variables: precipitación (12; 1,00 %), nivel del río (11; 0,92 %), caudal (9; 0,75 %) y saturación del suelo (9; 0,75 %). Ninguna variable supera el 1 % de ausencias y ningún registro carece del valor de la variable objetivo, de modo que el tratamiento de faltantes tiene un efecto marginal sobre las distribuciones y sobre el tamaño efectivo de la muestra. Estas cifras coinciden con los indicadores del módulo de carga de la aplicación (1.200 registros, 11 variables y 41 valores faltantes).

La zona hidrológica presenta una distribución desigual: Valle Bajo concentra 359 registros (29,9 %), Cuenca Media 327 (27,3 %), Cuenca Alta 261 (21,8 %) y Zona Urbana Costera 253 (21,1 %). El conteo de mantenimiento de canales toma valores enteros entre 0 y 8. Las variables expresadas en porcentaje respetan su rango físico: la saturación del suelo está acotada entre 10 % y 100 % y la humedad relativa entre 34 % y 100 %.

4.2. Estadística descriptiva de las variables

Tabla 3

Estadística descriptiva de las variables numéricas

Variable	n	Media	DE	Mín.	Q1	Mediana	Q3	Máx.	Asim.	Curt.
Precipitación (mm)	1188	46,9	23,4	0,0	29,7	45,7	62,6	124,8	0,24	-0,31
Caudal (m³/s)	1191	120,4	39,9	0,3	93,1	120,8	147,2	277,1	0,02	-0,03
Nivel del río (m)	1189	3,14	1,11	0,02	2,39	3,16	3,85	6,77	-0,03	-0,14
Saturación del suelo (%)	1191	64,5	17,2	10,0	53,3	64,6	76,8	100,0	-0,16	-0,15
Cobertura vegetal (%)	1200	39,3	15,4	5,0	28,4	39,0	49,8	92,9	0,14	-0,17
Temperatura (°C)	1200	22,0	5,2	3,6	18,5	21,9	25,7	37,6	-0,03	0,06
Humedad relativa (%)	1200	80,0	11,5	34,0	72,4	80,2	88,1	100,0	-0,25	-0,30
Mantenimiento (conteo)	1200	1,99	1,43	0,00	1,00	2,00	3,00	8,00	0,76	0,54

Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). n: observaciones no faltantes; DE: desviación estándar; Asim.: coeficiente de asimetría; Curt.: curtosis en exceso. Corresponde a la pestaña Resumen numérico del módulo 2.

Las siete variables continuas muestran distribuciones aproximadamente simétricas. En todas ellas la media y la mediana difieren en menos de 1,3 unidades de su escala original y el coeficiente de asimetría se encuentra entre −0,25 y 0,24, mientras que la curtosis en exceso varía entre −0,31 y 0,06, lo que indica colas comparables a las de una distribución normal. La

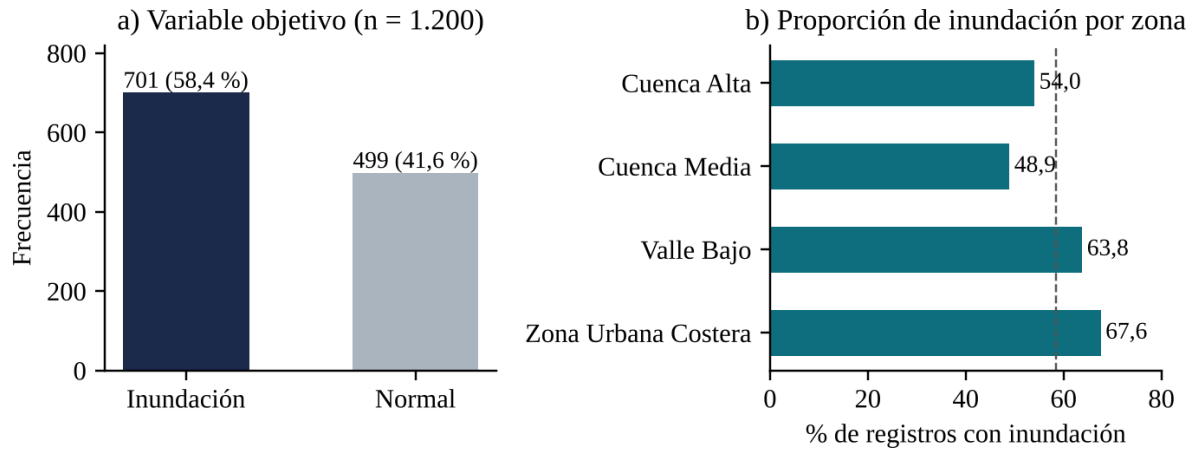
precipitación tiene una media de 46,9 mm (DE = 23,4) y un rango amplio, de 0,03 a 124,8 mm; el caudal, una media de 120,4 m³/s (DE = 39,9); el nivel del río, una media de 3,14 m (DE = 1,11), y la saturación del suelo, una media de 64,5 % (DE = 17,2). La única variable con asimetría apreciable es el conteo de mantenimiento de canales (asimetría 0,76; curtosis 0,54), cuya media de 1,99 y varianza de 2,04 (DE = 1,43) son compatibles con un proceso de tipo Poisson.

La simetría de las distribuciones hace innecesarias transformaciones previas al modelado y respalda el uso de la mediana como valor de imputación, que en estas variables es prácticamente igual a la media. El truncamiento de la saturación en 10 % y 100 % y de la humedad en 100 % se refleja en mínimos y máximos que coinciden con los límites físicos; estos valores son compatibles con una acotación deliberada del rango y no se trataron como atípicos.

4.3. Distribución de la variable objetivo y balance de clases

Figura 1

Distribución del estado de alerta y proporción de inundación por zona hidrológica



Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). La línea discontinua del panel b indica la proporción global de inundación (58,4 %).

La variable objetivo registra 701 casos de inundación (58,4 %) y 499 casos normales (41,6 %), una razón de 1,40 entre clases. El desbalance es moderado y no requiere técnicas de remuestreo, pero tiene dos consecuencias para la evaluación: la exactitud de un clasificador que siempre predice inundación sería 58,3 % en el conjunto de prueba, y los modelos sin corrección tienden a favorecer la clase mayoritaria. Por esa razón la aplicación incorpora pesos de clase y la comparación se apoya en métricas que no dependen de la prevalencia, como la especificidad, el MCC y el AUC.

Tabla 4

Distribución del estado de alerta según la zona hidrológica

Zona hidrológica	Inundación	Normal	Total	% inundación
Cuenca Alta	141	120	261	54,0
Cuenca Media	160	167	327	48,9
Valle Bajo	229	130	359	63,8
Zona Urbana Costera	171	82	253	67,6
Total	701	499	1200	58,4

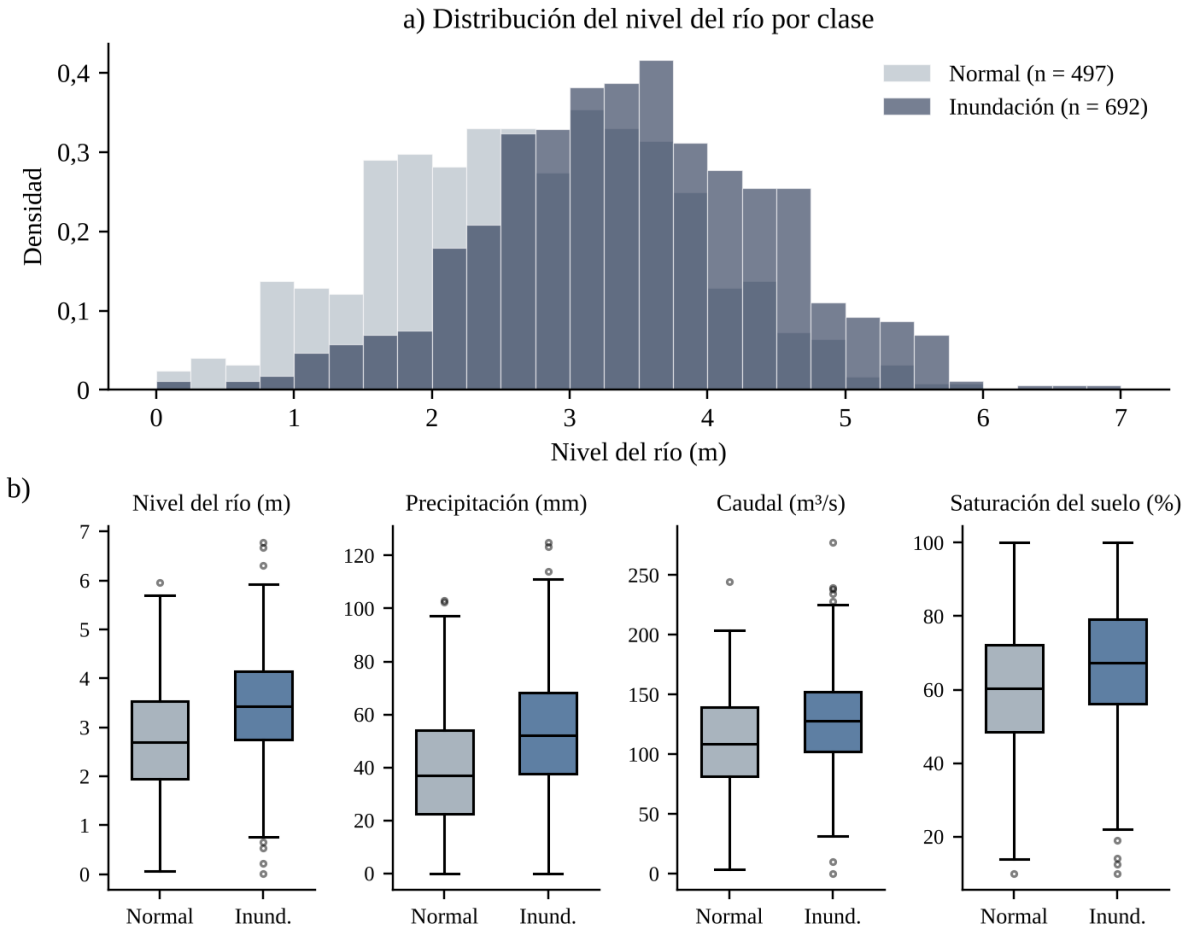
Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). Prueba ji cuadrado de independencia: $\chi^2(3) = 27{,}22$; $p < 0{,}001$; V de Cramér = 0,151.

La proporción de inundación varía entre zonas desde 48,9 % en Cuenca Media hasta 67,6 % en Zona Urbana Costera, con Valle Bajo (63,8 %) por encima del promedio y Cuenca Alta (54,0 %) por debajo. La asociación es estadísticamente significativa ($\chi^2(3) = 27{,}22$; $p < 0{,}001$), pero su magnitud es pequeña ($V = 0{,}151$): conocer la zona modifica la probabilidad de alerta en hasta 19 puntos porcentuales, aunque por sí sola no permite discriminar adecuadamente entre clases. Este resultado anticipa que la zona aportará información complementaria y no dominante en los modelos.

4.4. Análisis exploratorio y relaciones entre variables

Figura 2

Distribución del nivel del río por clase y diagramas de caja de las cuatro variables con mayor asociación



Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). Panel a: histogramas de densidad con intervalos de 0,25 m. Panel b: diagramas de caja de Tukey (bigotes hasta 1,5 veces el rango intercuartílico); los puntos representan valores fuera de ese rango. Se excluyen los valores faltantes de cada variable.

La Figura 2 muestra que las distribuciones condicionales de las variables hidrológicas están desplazadas hacia valores mayores en la clase de inundación, aunque se solapan ampliamente. La mediana del nivel del río es 2,70 m en la clase normal y 3,44 m en la clase de inundación, con medias de 2,74 y 3,43 m; la precipitación media pasa de 38,7 a 52,8 mm, el caudal medio de 110,1 a 127,6 m³/s y la saturación media del suelo de 60,4 % a 67,4 %. En sentido contrario, la cobertura vegetal media es menor en la clase de inundación (38,0 % frente a 41,0 %), al igual que el número medio de intervenciones de mantenimiento de canales (1,83 frente a 2,20). La temperatura (22,3 frente a 21,8 °C) y la humedad relativa (80,1 % frente a 79,9 %) prácticamente no difieren entre clases.

El solapamiento es el rasgo más relevante para el modelado. En el nivel del río, el rango intercuartílico de la clase normal (1,95 a 3,53 m) y el de la clase de inundación (2,75 a 4,14 m) comparten un tramo de casi 0,8 m, y en la precipitación y la saturación la superposición es aún mayor. Ninguna variable aislada separa las clases, de modo que el desempeño de los clasificadores dependerá de combinar varias señales moderadas. Esta característica impone un límite superior plausible a la capacidad discriminante, que se manifestará en AUC del orden de 0,8 y no próximos a 1.

4.5. Pruebas estadísticas y correlaciones

Tabla 5

Pruebas de asociación entre cada predictor y el estado de alerta

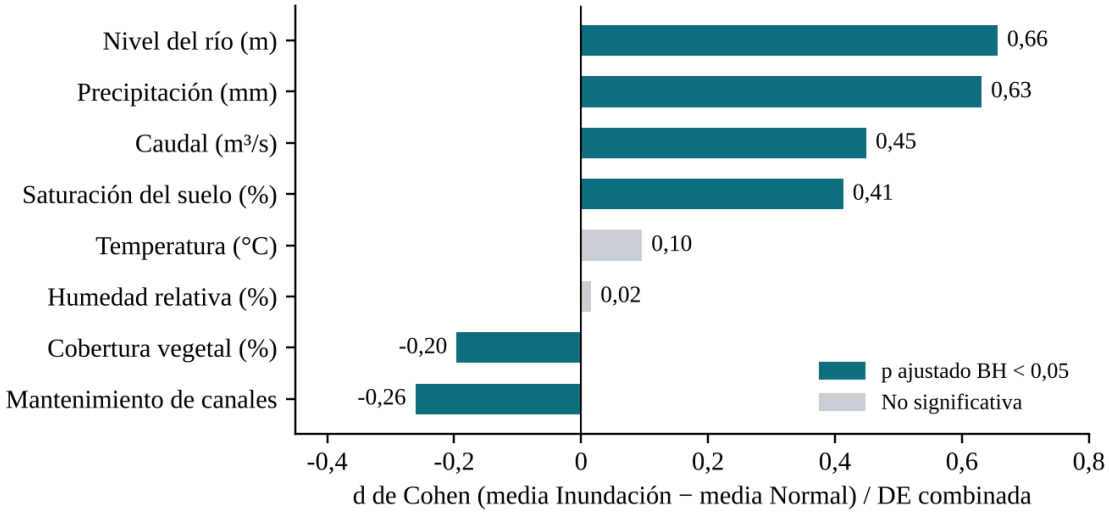
Variable	Prueba	Estadístico	*p*	*p* Wilcoxon	Efecto	*p* ajustado (BH)
Nivel del río (m)	t de Welch	-11,08	< 0,001	< 0,001	d = 0,656	< 0,001
Precipitación (mm)	t de Welch	-10,83	< 0,001	< 0,001	d = 0,631	< 0,001
Caudal (m³/s)	t de Welch	-7,55	< 0,001	< 0,001	d = 0,449	< 0,001
Saturación del suelo (%)	t de Welch	-7,00	< 0,001	< 0,001	d = 0,413	< 0,001
Zona hidrológica	Ji cuadrado	27,22	< 0,001	—	V = 0,151	< 0,001
Mantenimiento de canales	t de Welch	4,35	< 0,001	< 0,001	d = -0,261	< 0,001
Cobertura vegetal (%)	t de Welch	3,32	< 0,001	< 0,001	d = -0,196	0,001
Temperatura (°C)	t de Welch	-1,62	0,105	0,130	d = 0,096	0,118
Humedad relativa (%)	t de Welch	-0,26	0,791	0,685	d = 0,016	0,791

Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). Pestaña Pruebas de hipótesis vs. clase del módulo 2. El estadístico t se calcula como Normal − Inundación, por lo que valores negativos indican medias mayores en la clase de inundación; la d de Cohen se orienta como Inundación − Normal.

Tras el ajuste de Benjamini-Hochberg, siete de los nueve predictores presentan asociación significativa con el estado de alerta. Las magnitudes, sin embargo, son heterogéneas. El nivel del río (d = 0,656; t = −11,08) y la precipitación (d = 0,631; t = −10,83) muestran efectos de magnitud media según los criterios convencionales de Cohen; el caudal (d = 0,449) y la saturación del suelo (d = 0,413) muestran efectos entre pequeños y medios. El mantenimiento de canales (d = −0,261) y la cobertura vegetal (d = −0,196) tienen efectos pequeños y de signo negativo, es decir, valores mayores se asocian con menor frecuencia de inundación. La temperatura (d = 0,096; p ajustado = 0,118) y la humedad relativa (d = 0,016; p ajustado = 0,791) no muestran asociación. La prueba de Wilcoxon conduce a las mismas conclusiones en todas las variables numéricas, lo que indica que los resultados no dependen del supuesto de normalidad.

Figura 3

Tamaño de efecto de las variables numéricas sobre el estado de alerta

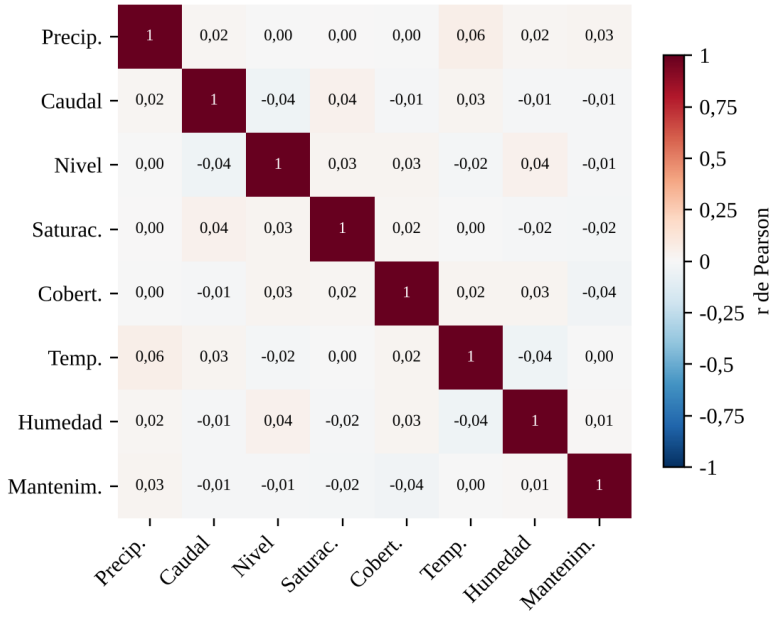


Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). La d de Cohen es la diferencia de medias (Inundación − Normal) dividida por la desviación estándar combinada. Color según significancia con *p* ajustado por Benjamini-Hochberg.

El ordenamiento de la Figura 3 anticipa la jerarquía que los modelos asignarán a los predictores. Con 1.200 observaciones, incluso efectos pequeños como el de la cobertura vegetal resultan significativos; por ello la significancia indica que la diferencia no es atribuible al azar, mientras que la *d* de Cohen indica cuánto contribuye cada variable a separar las clases. Dos variables con significancia comparable ($p < 0{,}001$) pueden tener utilidad predictiva muy distinta, como ocurre con el nivel del río y el mantenimiento de canales.

Figura 4

Matriz de correlaciones de Pearson entre los predictores numéricos



Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). Correlaciones calculadas con pares completos (pestaña Correlaciones del módulo 2).

Las correlaciones entre predictores son prácticamente nulas: el mayor valor absoluto fuera de la diagonal es 0,061 (precipitación y temperatura) y el resto se sitúa por debajo de 0,05. Desde el punto de vista del modelado, esta independencia elimina la multicolinealidad y hace que los coeficientes de la regresión logística sean estables e interpretables por separado. Desde el punto de vista sustantivo, es un indicio claro de que los datos son simulados: en una cuenca real la precipitación, el caudal y el nivel del río están fuertemente correlacionados por el propio proceso hidrológico. Esta diferencia limita la extrapolación de los resultados, porque en datos reales la redundancia entre predictores cambiaría la importancia relativa de las variables y podría modificar el ordenamiento de los modelos.

4.6. Preparación y partición de datos

Tabla 6

Resultado de la partición estratificada y de la ponderación de clases

Conjunto	Total	Inundación	Normal	% inundación	Peso inundación	Peso normal
Entrenamiento	960	561	399	58,44	0,856	1,203
Prueba	240	140	100	58,33	—	—
Total	1200	701	499	58,42	—	—

Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). Proporción de prueba 0,20; semilla 2024. Los pesos se calculan como $n/(2 \cdot nc)$ en entrenamiento y se aplican a todos los modelos excepto KNN.

La partición estratificada conservó la proporción de inundaciones en ambos conjuntos (58,44 % en entrenamiento y 58,33 % en prueba), de modo que las métricas de prueba no están sesgadas por un cambio de prevalencia. Tras la imputación y la codificación dummy, la matriz de diseño quedó con 11 columnas: tres indicadoras de zona y ocho variables numéricas. Los pesos de clase hacen que, en la función de pérdida, la contribución total de cada clase sea la misma (480 unidades de peso por clase), lo que equivale a entrenar como si la muestra estuviera balanceada.

Con 140 positivos y 100 negativos en prueba, cada falso negativo modifica la sensibilidad en 0,71 puntos porcentuales y cada falso positivo modifica la especificidad en 1 punto. El tamaño del conjunto de prueba determina también la precisión de las estimaciones: para una exactitud cercana a 0,73, el error estándar binomial es aproximadamente 0,029 y el intervalo de confianza al 95 % tiene una semiamplitud de unos 5,6 puntos porcentuales. Esta magnitud sirve como referencia para valorar las diferencias entre modelos que se presentan a continuación.

4.7. Resultados de la regresión logística

Tabla 7

Métricas de la regresión logística en entrenamiento y prueba

Métrica	Entrenamiento (n = 960)	Prueba (n = 240)	Diferencia
Accuracy	0,765	0,729	0,035
Precision	0,828	0,762	0,066
Recall (sensibilidad)	0,754	0,779	−0,025
Especificidad	0,779	0,660	0,119
F1-score	0,789	0,770	0,019
MCC	0,527	0,441	0,086
AUC	0,835	0,822	0,013
Log Loss	0,503	0,499	0,004
Brier Score	0,166	0,168	−0,002
Verdaderos positivos (VP)	423	109	—
Falsos negativos (FN)	138	31	—
Falsos positivos (FP)	88	34	—
Verdaderos negativos (VN)	311	66	—

Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). Umbral $\tau = 0,5$. Diferencia = entrenamiento − prueba. Las métricas de entrenamiento se calculan sin ponderar sobre los mismos datos usados en el ajuste.

En el conjunto de prueba, la regresión logística alcanzó una exactitud de 0,729 (175 de 240 casos correctamente clasificados), una sensibilidad de 0,779 (109 de 140 inundaciones detectadas) y una especificidad de 0,660 (66 de 100 casos normales reconocidos). Es el modelo

con mayor especificidad y mayor precisión (0,762) de los seis, lo que significa que sus alertas son las más confiables: el 76,2 % de los casos clasificados como inundación lo son efectivamente. El costo es una sensibilidad intermedia, con 31 inundaciones omitidas, y 34 falsas alarmas.

Su principal fortaleza es la discriminación y la calidad probabilística. El AUC de 0,822 (IC 95 %: 0,769–0,875) es el más alto de todos los modelos, y también obtiene el menor Log Loss (0,499) y el menor Brier Score (0,168). La diferencia entre entrenamiento y prueba es mínima en todas las métricas: el AUC pasa de 0,835 a 0,822 (brecha de 0,013) y el Brier de 0,166 a 0,168. Un modelo con 12 parámetros estimados con 960 observaciones tiene baja varianza, y estos resultados confirman que generaliza sin sobreajuste apreciable. El MCC de prueba (0,441) es algo inferior al de entrenamiento (0,527), una diferencia atribuible a la variación muestral de las métricas dependientes del umbral más que a sobreajuste, dado que el AUC apenas cambia.

Tabla 8

Odds ratio estimados por la regresión logística (por aumento de una desviación estándar)

Variable	Coeficiente β	Odds ratio	IC 95 %	*p*
Nivel del río (m)	0,868	2,383	2,006 – 2,832	< 0,001
Precipitación (mm)	0,837	2,310	1,939 – 2,752	< 0,001
Caudal (m³/s)	0,613	1,846	1,564 – 2,179	< 0,001
Saturación del suelo (%)	0,534	1,706	1,446 – 2,013	< 0,001
Zona: Urbana Costera	0,435	1,544	1,265 – 1,885	< 0,001
Zona: Valle Bajo	0,390	1,477	1,207 – 1,806	< 0,001
Temperatura (°C)	0,112	1,119	0,955 – 1,311	0,166
Humedad relativa (%)	0,033	1,034	0,883 – 1,211	0,679
Zona: Cuenca Media	0,017	1,018	0,838 – 1,236	0,861
Cobertura vegetal (%)	-0,395	0,674	0,573 – 0,792	< 0,001
Mantenimiento de canales	-0,414	0,661	0,565 – 0,774	< 0,001

Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). Tabla de odds ratio del módulo 6. Las variables numéricas están estandarizadas con media y DE de entrenamiento; las indicadoras de zona también, por lo que su OR corresponde a un aumento de una DE de la variable indicadora. Los intervalos y valores *p* son aproximados por el uso de pesos de clase.

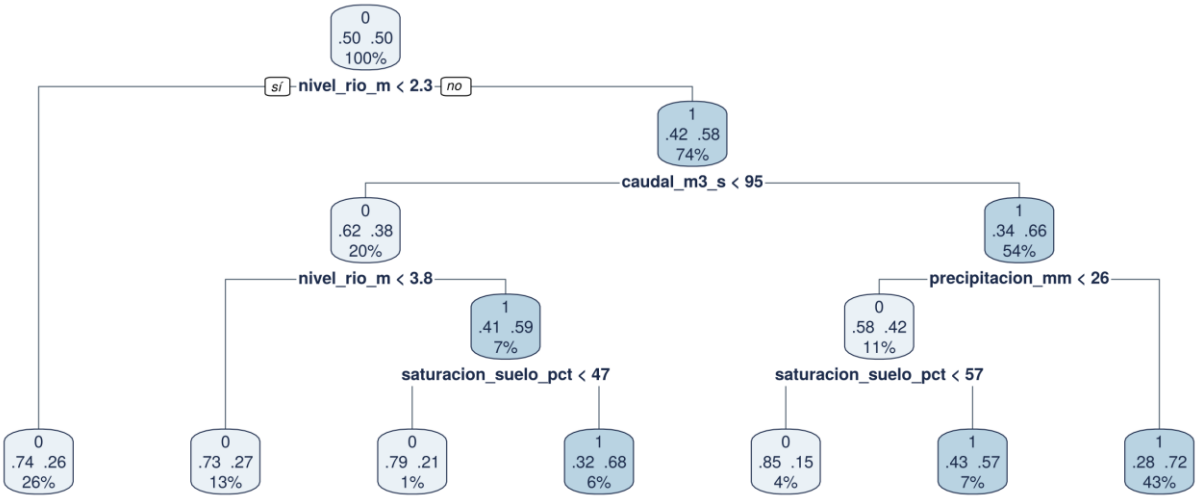
Los coeficientes confirman la dirección y la jerarquía observadas en el análisis exploratorio. Un aumento de una desviación estándar en el nivel del río (1,11 m) multiplica las odds de alerta por 2,38 (IC 95 %: 2,01–2,83), y uno en la precipitación (23,4 mm) por 2,31 (1,94–2,75), manteniendo constantes las demás variables. Les siguen el caudal (OR = 1,85) y la saturación del suelo (OR = 1,71). La cobertura vegetal (OR = 0,67) y el mantenimiento de canales (OR = 0,66) actúan como factores asociados a menor riesgo. Valle Bajo y Zona Urbana Costera elevan el riesgo respecto de Cuenca Alta, mientras que Cuenca Media no difiere de la

referencia (p = 0,861), y la temperatura y la humedad no son significativas. Ningún intervalo de confianza de las variables significativas incluye el valor 1, y la ausencia de correlación entre predictores hace que estas estimaciones condicionales coincidan en dirección con las asociaciones marginales de la Tabla 5.

4.8. Resultados del árbol de decisión

Figura 5

Árbol de decisión ajustado para la clasificación del estado de alerta



Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). Gráfico generado con rpart.plot (módulo 6). En cada nodo: clase predicha (0 = Normal, 1 = Inundación), probabilidades de cada clase y porcentaje de casos; las probabilidades y porcentajes están ponderados por los pesos de clase, por lo que el nodo raíz muestra 0,50/0,50.

Tabla 9

Reglas de las hojas del árbol de decisión

Hoja	Regla de decisión	n (sin ponderar)	P(inundación)	Clase
2	nivel_rio_m < 2,315	227	0,264	Normal
12	nivel ≥ 2,315; caudal < 94,86; nivel < 3,765	115	0,267	Normal
26	nivel ≥ 3,765; caudal < 94,86; saturación < 47,25	11	0,211	Normal
27	nivel ≥ 3,765; caudal < 94,86; saturación ≥ 47,25	59	0,676	Inundación
28	nivel ≥ 2,315; caudal ≥ 94,86; precipitación < 26,205; saturación < 56,6	35	0,151	Normal
29	nivel ≥ 2,315; caudal ≥ 94,86; precipitación < 26,205; saturación ≥ 56,6	69	0,571	Inundación
15	nivel ≥ 2,315; caudal ≥ 94,86; precipitación ≥ 26,205	444	0,718	Inundación

Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). Unidades: nivel en m, caudal en m³/s, precipitación en mm y saturación en %. P(inundación) es la proporción ponderada de la clase positiva en la hoja.

El árbol utilizó cuatro variables (nivel del río, caudal, precipitación y saturación del suelo) y terminó con siete hojas. La primera partición separa los registros con nivel del río inferior a 2,315 m, que reciben una probabilidad de inundación de 0,264. La rama de mayor

riesgo, que agrupa 444 de los 960 registros de entrenamiento, combina nivel del río de al menos 2,315 m, caudal de al menos 94,86 m³/s y precipitación de al menos 26,2 mm, con probabilidad 0,718. La saturación del suelo actúa como variable de desempate en dos ramas intermedias. Estas reglas tienen valor operativo porque expresan umbrales verificables en campo, y su estructura es coherente con la Tabla 5: las cuatro variables con mayor tamaño de efecto son las únicas que intervienen. La zona, la cobertura vegetal y el mantenimiento, cuyos efectos son pequeños, no alcanzaron el umbral de mejora requerido por cp = 0,01.

Tabla 10

Métricas del árbol de decisión en entrenamiento y prueba

Métrica	Entrenamiento (n = 960)	Prueba (n = 240)	Diferencia
Accuracy	0,728	0,742	−0,014
Precision	0,762	0,757	0,006
Recall (sensibilidad)	0,777	0,821	−0,044
Especificidad	0,659	0,630	0,029
F1-score	0,770	0,788	−0,018
MCC	0,438	0,462	−0,024
AUC	0,734	0,752	−0,018
Log Loss	0,588	0,568	0,020
Brier Score	0,199	0,190	0,010
Verdaderos positivos (VP)	436	115	—
Falsos negativos (FN)	125	25	—
Falsos positivos (FP)	136	37	—
Verdaderos negativos (VN)	263	63	—

Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). Umbral $\tau = 0,5$. Diferencia = entrenamiento − prueba. Las métricas de entrenamiento se calculan sin ponderar sobre los mismos datos usados en el ajuste.

En prueba, el árbol obtuvo una exactitud de 0,742, la segunda más alta, con sensibilidad de 0,821 (115 de 140) y especificidad de 0,630 (63 de 100). Su F1 (0,788) y su MCC (0,462) son también los segundos mejores. Sin embargo, su AUC es de 0,752 (IC 95 %: 0,691–0,814), inferior al de la logística, XGBoost, Random Forest y SVM. La explicación es estructural: con siete hojas, el árbol solo puede producir siete valores distintos de probabilidad, de modo que todos los casos de una hoja quedan empatados y la curva ROC se reduce a una poligonal de siete vértices. El árbol clasifica bien con el umbral 0,5 porque sus hojas están bien situadas a uno y otro lado de ese valor, pero ordena mal los casos dentro de cada hoja. Por la misma razón, su Log Loss (0,568) y su Brier Score (0,190) son de los menos favorables.

El árbol no muestra sobreajuste. Su AUC de entrenamiento (0,734) es incluso inferior al de prueba (0,752), y la exactitud de entrenamiento (0,728) es menor que la de prueba (0,742). Un desempeño igual o mejor fuera de la muestra en un modelo de baja complejidad indica

subajuste: el árbol con profundidad 4 es demasiado simple para capturar toda la señal disponible, y la diferencia favorable a prueba se explica por la variación muestral de una partición concreta. El laboratorio de complejidad (sección 4.16) confirma que una profundidad mayor mejora el AUC de prueba hasta cierto punto.

4.9. Resultados de Random Forest

Tabla 11

Métricas de Random Forest en entrenamiento y prueba

Métrica	Entrenamiento (n = 960)	Prueba (n = 240)	Diferencia
Accuracy	0,992	0,746	0,246
Precision	0,998	0,745	0,253
Recall (sensibilidad)	0,988	0,857	0,130
Especificidad	0,997	0,590	0,407
F1-score	0,993	0,797	0,195
MCC	0,983	0,469	0,514
AUC	1,000	0,804	0,196
Log Loss	0,222	0,528	−0,307
Brier Score	0,048	0,176	−0,128
Verdaderos positivos (VP)	554	120	—
Falsos negativos (FN)	7	20	—
Falsos positivos (FP)	1	41	—
Verdaderos negativos (VN)	398	59	—

Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). Umbral $\tau = 0,5$. Diferencia = entrenamiento − prueba. Las métricas de entrenamiento se calculan sin ponderar sobre los mismos datos usados en el ajuste.

Random Forest alcanzó en prueba la mayor exactitud (0,746; 179 de 240 casos), la mayor sensibilidad, compartida con KNN (0,857; 120 de 140 inundaciones detectadas), el mayor F1 (0,797) y el mayor MCC (0,469). Su especificidad, en cambio, fue de 0,590, con 41 falsas alarmas, inferior a la de la logística (34) y del árbol (37). La alta sensibilidad debe interpretarse, por tanto, junto con ese número de falsas alarmas: el modelo identifica una proporción elevada de los eventos porque asigna probabilidades superiores a 0,5 a una fracción mayor de casos. Su AUC de 0,804 (IC 95 %: 0,747–0,861) mejora claramente el del árbol individual (0,752), lo que ilustra el efecto del ensamble al promediar 300 árboles: las probabilidades dejan de ser escalonadas y el ordenamiento de los casos mejora.

El contraste entre entrenamiento y prueba es el más pronunciado de todos los modelos. En entrenamiento, el bosque alcanza una exactitud de 0,992, un AUC de 1,000 y un Brier de 0,048, es decir, prácticamente memoriza los datos con los que fue ajustado, lo que es esperable con árboles profundos y nodos terminales de hasta cinco casos. La brecha de AUC es de 0,196

y la de exactitud de 0,246. Esta brecha no impide un buen desempeño fuera de la muestra, porque el promedio de árboles decorrelacionados compensa la varianza individual; el error out-of-bag, de 28,1 %, es coherente con el error de prueba (25,4 %) y constituye una estimación honesta de la generalización, a diferencia de las métricas de entrenamiento. La conclusión correcta es que el ajuste en entrenamiento de Random Forest no debe utilizarse como indicador de desempeño.

4.10. Resultados de XGBoost

Tabla 12

Métricas de XGBoost en entrenamiento y prueba

Métrica	Entrenamiento (n = 960)	Prueba (n = 240)	Diferencia
Accuracy	0,842	0,708	0,133
Precision	0,881	0,736	0,144
Recall (sensibilidad)	0,843	0,779	0,065
Especificidad	0,840	0,610	0,230
F1-score	0,862	0,757	0,105
MCC	0,678	0,394	0,284
AUC	0,927	0,811	0,116
Log Loss	0,391	0,510	−0,119
Brier Score	0,119	0,170	−0,051
Verdaderos positivos (VP)	473	109	—
Falsos negativos (FN)	88	31	—
Falsos positivos (FP)	64	39	—
Verdaderos negativos (VN)	335	61	—

Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). Umbral $\tau = 0,5$. Diferencia = entrenamiento − prueba. Las métricas de entrenamiento se calculan sin ponderar sobre los mismos datos usados en el ajuste.

XGBoost obtuvo en prueba el segundo mejor AUC (0,811; IC 95 %: 0,756–0,866), el segundo mejor Log Loss (0,510) y el segundo mejor Brier (0,170), muy próximos a los de la regresión logística. Con el umbral 0,5, sin embargo, su exactitud fue de 0,708, la penúltima, con 31 omisiones y 39 falsas alarmas, sensibilidad de 0,779 y especificidad de 0,610. Este contraste entre buena discriminación y exactitud modesta muestra que ordenar bien los casos no garantiza clasificarlos bien con un umbral fijo: el valor scale_pos_weight = 0,711 reduce el peso relativo de la clase positiva, desplaza las probabilidades hacia abajo y hace que una parte de los casos positivos quede justo por debajo de 0,5.

La brecha entre entrenamiento (AUC = 0,927; exactitud = 0,842) y prueba (AUC = 0,811) es de 0,116 en AUC, lo que indica un sobreajuste moderado. El laboratorio de complejidad muestra que el AUC de prueba alcanza su máximo, 0,830, con 70 rondas y

desciende gradualmente a 0,812 con 145 rondas, mientras el AUC de entrenamiento sigue aumentando. Las 150 rondas utilizadas superan, por tanto, el punto de mejor generalización observado; con una tasa de aprendizaje de 0,05, una configuración con menos rondas o con detención temprana basada en validación cruzada sería preferible.

4.11. Resultados de SVM

Tabla 13

Métricas de la SVM en entrenamiento y prueba

Métrica	Entrenamiento (n = 960)	Prueba (n = 240)	Diferencia
Accuracy	0,828	0,721	0,107
Precision	0,840	0,724	0,116
Recall (sensibilidad)	0,872	0,843	0,029
Especificidad	0,767	0,550	0,217
F1-score	0,856	0,779	0,077
MCC	0,644	0,415	0,229
AUC	0,898	0,785	0,113
Log Loss	0,419	0,547	−0,128
Brier Score	0,128	0,186	−0,058
Verdaderos positivos (VP)	489	118	—
Falsos negativos (FN)	72	22	—
Falsos positivos (FP)	93	45	—
Verdaderos negativos (VN)	306	55	—

Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). Umbral $\tau = 0{,}5$. Diferencia = entrenamiento − prueba. Las métricas de entrenamiento se calculan sin ponderar sobre los mismos datos usados en el ajuste.

La SVM con núcleo radial ($C = 1$, $\gamma = 0{,}1$) alcanzó en prueba una exactitud de 0,721, una sensibilidad de 0,843 (118 de 140) y una especificidad de 0,550 (55 de 100), con 45 falsas alarmas. Su AUC fue de 0,785 (IC 95 %: 0,728–0,843), su Log Loss de 0,547 y su Brier de 0,186, valores intermedios. Un indicador diagnóstico relevante es que 641 de las 960 observaciones de entrenamiento (66,8 %) quedaron como vectores de soporte; una proporción tan elevada señala que la mayoría de los casos se sitúan dentro del margen o del lado incorrecto de la frontera, lo que concuerda con el amplio solapamiento entre clases observado en el análisis exploratorio.

La combinación de alta sensibilidad y baja especificidad depende del umbral aplicado a las probabilidades de Platt, que tienden a concentrarse en valores altos: la mediana de la probabilidad estimada para los casos normales de prueba es 0,47, superior a la de la regresión logística (0,34). Como se muestra en la sección 4.18, al elevar el umbral la sensibilidad y la especificidad de la SVM se igualan en torno a $\tau \approx 0{,}65$. La brecha de AUC entre entrenamiento

(0,898) y prueba (0,785) es de 0,113, un sobreajuste moderado asociado a la flexibilidad del núcleo radial con $\gamma = 0{,}1$ en 11 dimensiones.

4.12. Resultados de KNN

Tabla 14

Métricas de KNN en entrenamiento y prueba

Métrica	Entrenamiento (n = 960)	Prueba (n = 240)	Diferencia
Accuracy	0,765	0,679	0,085
Precision	0,759	0,678	0,081
Recall (sensibilidad)	0,875	0,857	0,018
Especificidad	0,609	0,430	0,179
F1-score	0,813	0,757	0,056
MCC	0,509	0,322	0,187
AUC	0,832	0,725	0,107
Log Loss	0,511	0,665	−0,154
Brier Score	0,169	0,209	−0,040
Verdaderos positivos (VP)	491	120	—
Falsos negativos (FN)	70	20	—
Falsos positivos (FP)	156	57	—
Verdaderos negativos (VN)	243	43	—

Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). Umbral $\tau = 0{,}5$. Diferencia = entrenamiento − prueba. Las métricas de entrenamiento se calculan sin ponderar sobre los mismos datos usados en el ajuste.

KNN con $k = 15$ registró la menor exactitud de los seis modelos (0,679), aunque superior a la tasa de referencia de 0,583. Su sensibilidad de 0,857 (120 de 140) iguala la de Random Forest, pero su especificidad de 0,430 es la más baja: 57 de los 100 casos normales fueron clasificados como inundación. También presenta los valores menos favorables de AUC (0,725; IC 95 %: 0,660–0,791), Log Loss (0,665) y Brier (0,209). El patrón se explica por dos características del método. Primero, KNN es el único modelo sin ponderación de clases, de modo que las vecindades reflejan la proporción de 58 % de inundaciones del entrenamiento y el voto favorece sistemáticamente la clase mayoritaria; la mediana de la probabilidad estimada para los casos normales de prueba es 0,53, superior al umbral. Segundo, la distancia euclídea otorga el mismo peso a todos los predictores estandarizados, incluidos la temperatura y la humedad, que no aportan información y degradan la noción de vecindad.

Las métricas de entrenamiento de KNN (AUC = 0,832) están infladas porque cada observación de entrenamiento se cuenta como su propio vecino al evaluarla, por lo que la brecha de 0,107 debe leerse con cautela. El laboratorio de complejidad muestra el comportamiento característico del método: con $k = 1$ el AUC de entrenamiento es 1,000 y el de prueba 0,560, y

al aumentar *k* el modelo se suaviza y el AUC de prueba crece hasta un máximo de 0,752 con *k* = 41. El valor *k* = 15 se encuentra, por tanto, en una región de desempeño estable pero no óptima.

4.13. Comparación general de los seis modelos

Tabla 15

Métricas de los seis modelos en el conjunto de prueba

Modelo	Acc.	Prec.	Recall	Esp.	F1	MCC	AUC	Log Loss	Brier
Regresión logística	0,729	0,762*	0,779	0,660*	0,770	0,441	0,822*	0,499*	0,168*
Árbol de decisión	0,742	0,757	0,821	0,630	0,788	0,462	0,752	0,568	0,190
Random Forest	0,746*	0,745	0,857*	0,590	0,797*	0,469*	0,804	0,528	0,176
XGBoost	0,708	0,736	0,779	0,610	0,757	0,394	0,811	0,510	0,170
SVM	0,721	0,724	0,843	0,550	0,779	0,415	0,785	0,547	0,186
KNN	0,679	0,678	0,857*	0,430	0,757	0,322	0,725	0,665	0,209

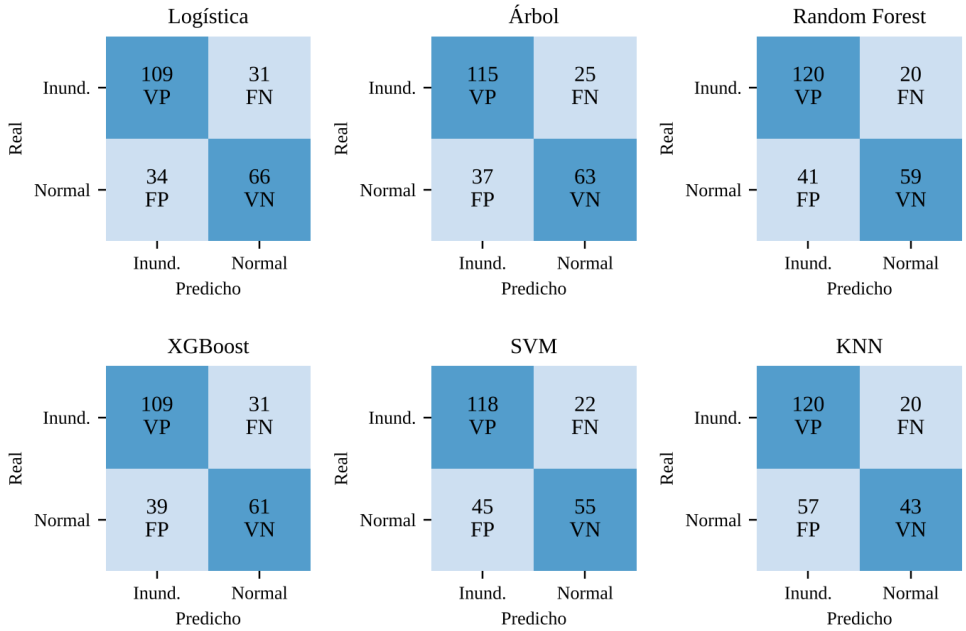
Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). n = 240 (140 inundaciones y 100 casos normales); umbral $\tau = 0,5$. * Mejor valor de la columna (para Log Loss y Brier, el menor). La sensibilidad de Random Forest y KNN es idéntica (120/140). Corresponde a la tabla Métricas en el conjunto de prueba del módulo 5.

La Tabla 15 muestra que ningún modelo obtiene el mejor valor en todas las métricas. Random Forest lidera las cuatro métricas que dependen del umbral y que favorecen la detección de la clase positiva: exactitud (0,746), sensibilidad (0,857, empatada con KNN), F1 (0,797) y MCC (0,469). La regresión logística lidera las cinco restantes: precisión (0,762), especificidad (0,660), AUC (0,822), Log Loss (0,499) y Brier (0,168). La división no es casual. Las métricas en las que gana Random Forest valoran el número de aciertos con $\tau = 0,5$ y, en el caso de la sensibilidad y el F1, premian la detección de positivos; las métricas en las que gana la logística valoran la confiabilidad de las alertas, el ordenamiento de los casos y la calidad de las probabilidades.

Las diferencias entre los cuatro modelos con mayor exactitud son pequeñas en términos absolutos. Random Forest (0,746), el árbol (0,742) y la logística (0,729) se separan por 1 y 4 casos acertados sobre 240, y XGBoost (0,708) y SVM (0,721) quedan a 9 y 6 casos de Random Forest. Solo KNN se distancia de forma consistente del resto, con la menor exactitud, la menor especificidad, el menor MCC y el menor AUC. El MCC, que resume las cuatro celdas de la matriz de confusión, oscila entre 0,322 y 0,469: todos los modelos establecen una correlación moderada entre la clase predicha y la observada, lo que es coherente con el solapamiento de las distribuciones descrito en la sección 4.4.

Figura 6

Matrices de confusión de los seis modelos en el conjunto de prueba

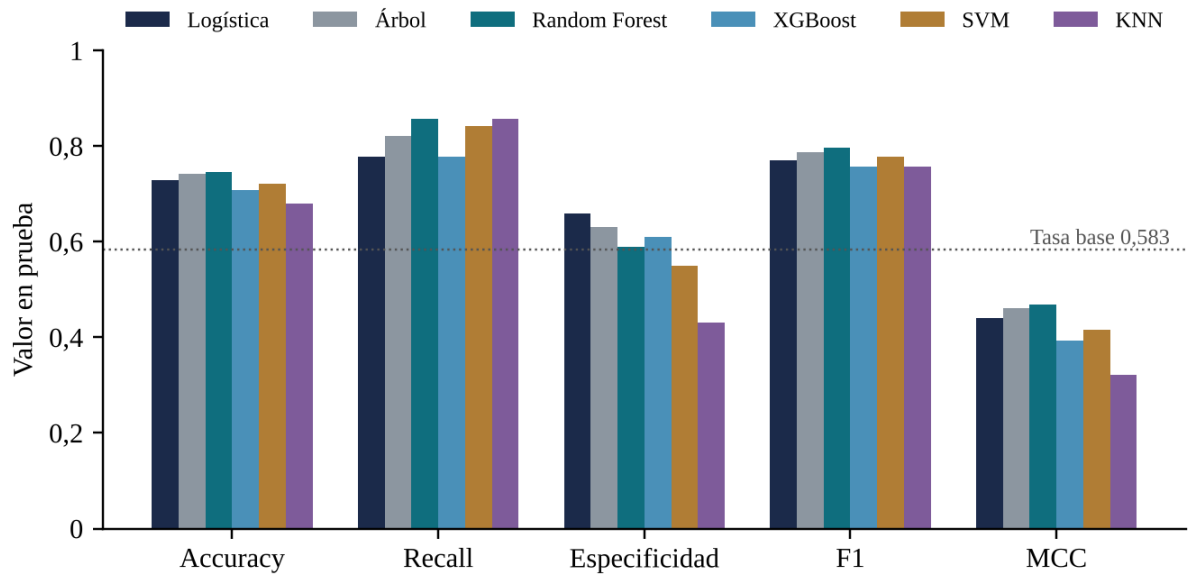


Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). Filas: clase real; columnas: clase predicha con $\tau = 0{,}5$. VP: verdaderos positivos; FN: falsos negativos; FP: falsos positivos; VN: verdaderos negativos. El módulo 5 de la aplicación muestra la matriz del modelo seleccionado; aquí se presentan las seis.

Las matrices de confusión hacen visible el intercambio entre omisiones y falsas alarmas. Los modelos con más inundaciones detectadas, Random Forest y KNN con 120 verdaderos positivos y la SVM con 118, son los que más falsas alarmas emiten (41, 57 y 45, respectivamente). La regresión logística y XGBoost detectan 109 inundaciones cada uno, pero la logística emite 34 falsas alarmas frente a 39 de XGBoost. El árbol ocupa una posición intermedia con 115 detecciones y 37 falsas alarmas. Si se suman los dos tipos de error, Random Forest comete 61, el árbol 62, la logística 65, la SVM 67, XGBoost 70 y KNN 77; la composición del error, sin embargo, es tan relevante como su total en un sistema de alerta.

Figura 7

Comparación de exactitud, sensibilidad, especificidad, F1 y MCC entre modelos



Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). Conjunto de prueba, $\tau = 0{,}5$. La línea punteada indica la tasa de referencia (0,583), exactitud de un clasificador que predice siempre inundación.

La Figura 7 muestra un patrón cruzado entre sensibilidad y especificidad. Los modelos ordenados de mayor a menor sensibilidad (Random Forest y KNN, SVM, árbol, logística y XGBoost) aparecen en orden casi inverso en especificidad. Con un umbral fijo, la posición de cada modelo en este intercambio depende de cómo se distribuyen sus probabilidades: un modelo cuyas probabilidades tienden a ser altas clasifica más casos como inundación, lo que aumenta la sensibilidad pero convierte más casos normales en falsas alarmas. KNN, sin ponderación de clases, y la SVM, con probabilidades de Platt desplazadas hacia arriba, se ubican en el extremo de alta sensibilidad; la logística, con probabilidades más dispersas y mejor ordenadas, en el de alta especificidad.

Tabla 16

Comparación pareada de la exactitud de Random Forest con los demás modelos (prueba exacta de McNemar)

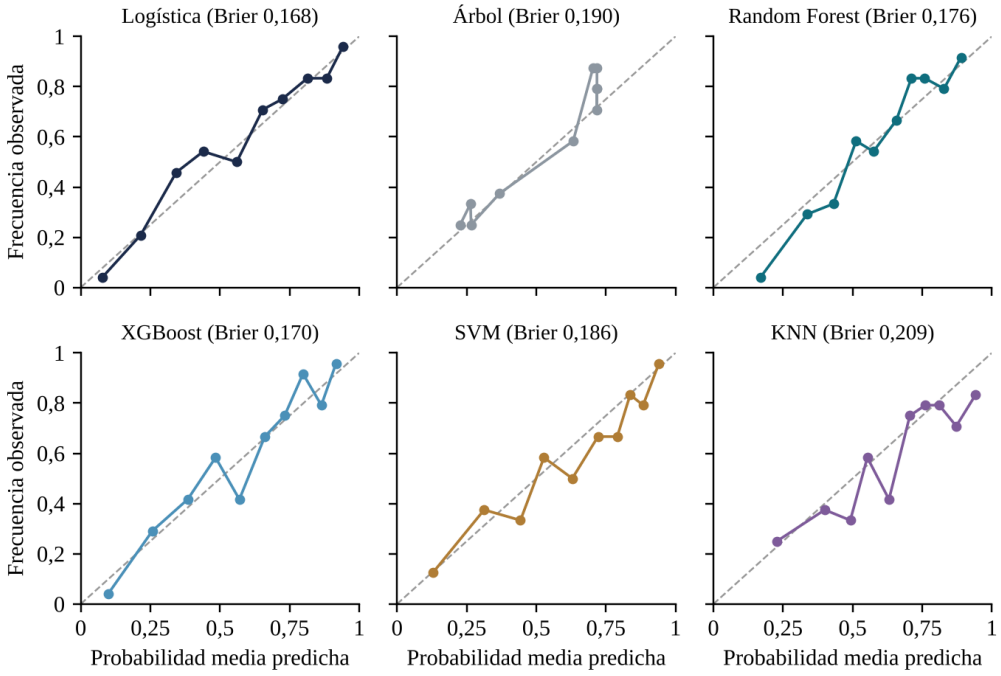
Comparación	Dif. de exactitud	Solo RF acierta	Solo el otro acierta	*p* exacto	*p* Holm
Random Forest vs. Regresión logística	+0,017	18	14	0,597	1,000
Random Forest vs. Árbol de decisión	+0,004	24	23	1,000	1,000
Random Forest vs. XGBoost	+0,037	16	7	0,093	0,372
Random Forest vs. SVM	+0,025	15	9	0,307	0,922
Random Forest vs. KNN	+0,067	31	15	0,026	0,130

Nota. Análisis complementario calculado sobre las predicciones de prueba reproducidas (no disponible en la interfaz de la aplicación). La prueba utiliza solo los casos en que exactamente uno de los dos modelos acierta. Intervalo bootstrap percentil al 95 % (5.000 remuestreos) para la diferencia de exactitud entre Random Forest y la regresión logística: −0,029 a 0,063.

La prueba de McNemar confirma que las diferencias de exactitud no son concluyentes. Random Forest y la regresión logística discrepan en 32 casos, de los cuales Random Forest acierta en 18 y la logística en 14; la probabilidad de un desequilibrio igual o mayor bajo la hipótesis de igual exactitud es 0,597. El intervalo bootstrap para la diferencia (−2,9 a +6,3 puntos porcentuales) incluye el cero. Frente al árbol, la diferencia se apoya en 24 frente a 23 casos discordantes (p = 1,000). La única comparación con p nominal inferior a 0,05 es la de Random Forest frente a KNN (p = 0,026), que deja de ser significativa tras el ajuste de Holm por cinco comparaciones (p = 0,130). En consecuencia, Random Forest es el modelo con mayor exactitud observada, pero los datos de prueba no permiten afirmar que su exactitud sea superior a la de los demás.

Figura 8

Curvas de calibración por deciles de probabilidad predicha en el conjunto de prueba



Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). Cada punto representa un decil de probabilidad predicha (24 casos): abscisa, probabilidad media predicha; ordenada, proporción observada de inundaciones. La diagonal discontinua corresponde a la calibración perfecta. Gráfico Calibración de probabilidades del módulo 5.

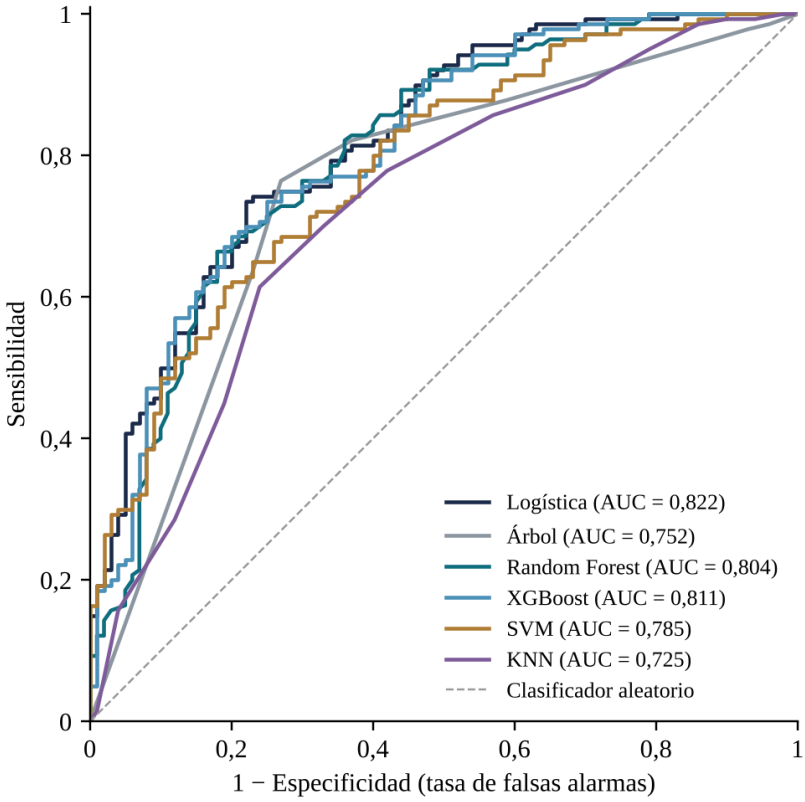
La calidad probabilística ordena los modelos de forma distinta a la exactitud. Según el Log Loss, el orden es logística (0,499), XGBoost (0,510), Random Forest (0,528), SVM (0,547), árbol (0,568) y KNN (0,665); el Brier Score reproduce el mismo orden (de 0,168 a

0,209). Ambos son reglas de puntuación propias, de modo que un valor menor indica probabilidades más próximas a los resultados observados en conjunto, pero no separan la discriminación de la calibración. Las curvas de la Figura 8 permiten examinar la calibración de forma descriptiva: la logística y XGBoost siguen razonablemente la diagonal en todo el rango; el árbol concentra sus predicciones en unos pocos valores, con cuatro deciles en 0,718; KNN se aleja de la diagonal en los deciles altos, donde predice probabilidades de 0,87 a 0,94 para grupos con frecuencias observadas de 0,71 a 0,83. Con 24 casos por decil, cada proporción observada tiene un error estándar cercano a 0,10, por lo que estas curvas son indicativas y no constituyen una prueba formal de calibración. Además, los pesos de clase desplazan intencionalmente las probabilidades respecto de la prevalencia observada, de modo que ningún modelo ponderado debería considerarse calibrado sin una recalibración posterior.

4.14. Curvas ROC y análisis de AUC

Figura 9

Curvas ROC de los seis modelos en el conjunto de prueba



Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). Curvas calculadas con pROC (gráfico Curvas ROC del módulo 5). La diagonal corresponde a un clasificador sin capacidad discriminante (AUC = 0,5).

Tabla 17

AUC en prueba, intervalos de confianza y comparación con la regresión logística (prueba de DeLong)

Modelo	AUC	IC 95 %	Diferencia vs. logística	*p* DeLong	*p* Holm
Regresión logística	0,822	0,769 – 0,875	Referencia	—	—
XGBoost	0,811	0,756 – 0,866	−0,011	0,417	0,599
Random Forest	0,804	0,747 – 0,861	−0,018	0,299	0,599
SVM	0,785	0,728 – 0,843	−0,036	0,012	0,0495
Árbol de decisión	0,752	0,691 – 0,814	−0,069	0,033	0,098
KNN	0,725	0,660 – 0,791	−0,096	< 0,001	< 0,001

Nota. Análisis complementario con pROC: intervalos por el método de DeLong y prueba de DeLong pareada (los seis modelos se evalúan sobre los mismos 240 casos). Ajuste de Holm por cinco comparaciones.

La curva ROC de la regresión logística se sitúa por encima de las demás entre tasas de falsas alarmas de aproximadamente 0,05 y 0,25, región relevante cuando se desea mantener acotado el número de alertas injustificadas; en ese tramo alcanza sensibilidades de 0,40 a 0,74. Las curvas de XGBoost (0,811) y Random Forest (0,804) se aproximan y entrecruzan con la de la logística para tasas de falsas alarmas mayores. La curva del árbol consiste en pocos segmentos rectos, consecuencia de sus siete valores de probabilidad, y la de KNN queda por debajo de las demás en casi todo el rango.

Los intervalos de confianza de la Tabla 17 se solapan ampliamente entre los cuatro primeros modelos, y la prueba de DeLong lo confirma: la diferencia entre la logística y XGBoost (0,011; $p = 0,417$) y entre la logística y Random Forest (0,018; $p = 0,299$) no es significativa. Las diferencias frente a la SVM (0,037; $p = 0,012$), al árbol (0,069; $p = 0,033$) y a KNN (0,096; $p < 0,001$) son significativas a nivel nominal; tras el ajuste de Holm se mantienen la diferencia con KNN ($p < 0,001$) y, en el límite, con la SVM ($p = 0,0495$), mientras que la del árbol deja de serlo ($p = 0,098$). La evidencia permite afirmar que la logística discrimina mejor que KNN, y con menor seguridad que la SVM, pero no que discrimine mejor que XGBoost o Random Forest.

Los resultados ilustran por qué el modelo con mayor exactitud no tiene necesariamente el mayor AUC. La exactitud evalúa un único punto de la curva ROC, el correspondiente a $\tau = 0,5$, y depende de dónde se sitúan las probabilidades respecto de ese umbral. El AUC, en cambio, resume el ordenamiento de todos los pares de casos positivo-negativo, con independencia del umbral. Random Forest sitúa a más casos del lado correcto de 0,5, mientras que la logística ordena mejor los casos a lo largo de todo el rango de probabilidades. El árbol es el ejemplo extremo: segundo en exactitud y penúltimo en AUC.

4.15. Validación cruzada y estabilidad de los modelos

Tabla 18

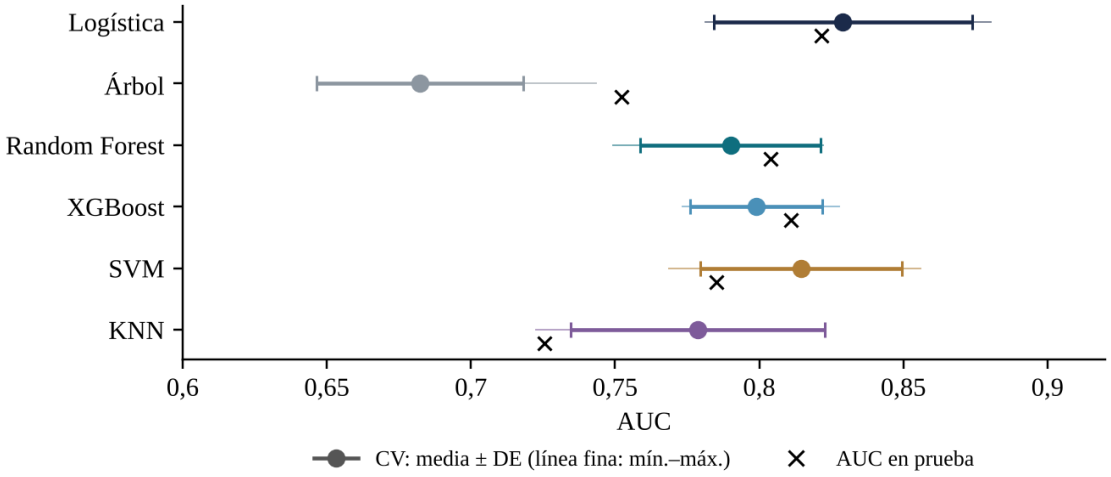
AUC en validación cruzada estratificada de cinco pliegues sobre el conjunto de entrenamiento

Modelo	AUC medio	DE	Mínimo	Máximo	AUC en prueba
Regresión logística	0,829	0,045	0,781	0,880	0,822
SVM	0,815	0,035	0,769	0,856	0,785
XGBoost	0,799	0,023	0,773	0,828	0,811
Random Forest	0,790	0,031	0,749	0,822	0,804
KNN	0,779	0,044	0,723	0,815	0,725
Árbol de decisión	0,682	0,036	0,656	0,743	0,752

Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). Opción «Validación cruzada k-fold» del módulo 4, desactivada por defecto en la aplicación y ejecutada para este informe con k = 5, la misma semilla y los mismos hiperparámetros, sobre los 960 registros de entrenamiento.

Figura 10

AUC en validación cruzada (media ± DE y rango) frente al AUC en el conjunto de prueba



Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). Cada pliegue de validación contiene 192 registros.

La validación cruzada confirma el liderazgo de la regresión logística en discriminación, con un AUC medio de 0,829 (DE = 0,045), seguida por la SVM (0,815), XGBoost (0,799), Random Forest (0,790), KNN (0,779) y el árbol (0,682). Este ordenamiento difiere del de prueba en las posiciones intermedias: la SVM, cuarta en prueba (0,785), es segunda en validación cruzada, y KNN mejora de 0,725 a 0,779. Las desviaciones estándar entre pliegues, entre 0,023 y 0,045, son del mismo orden que las diferencias entre los modelos intermedios, lo que indica que su ordenamiento es sensible a la partición concreta y que una única partición de prueba no basta para establecerlo.

Dos resultados son estables en ambos procedimientos: la logística ocupa el primer lugar y el árbol con profundidad 4 el último en AUC. XGBoost presenta la menor variabilidad entre pliegues (DE = 0,023), lo que indica estabilidad, mientras que la logística y KNN muestran las mayores (0,045 y 0,044). El árbol obtiene en validación cruzada un AUC claramente inferior al de prueba (0,682 frente a 0,752), lo que confirma que su capacidad discriminante es limitada y que el valor de prueba se vio favorecido por la partición.

4.16. Diagnóstico de sobreajuste

Tabla 19

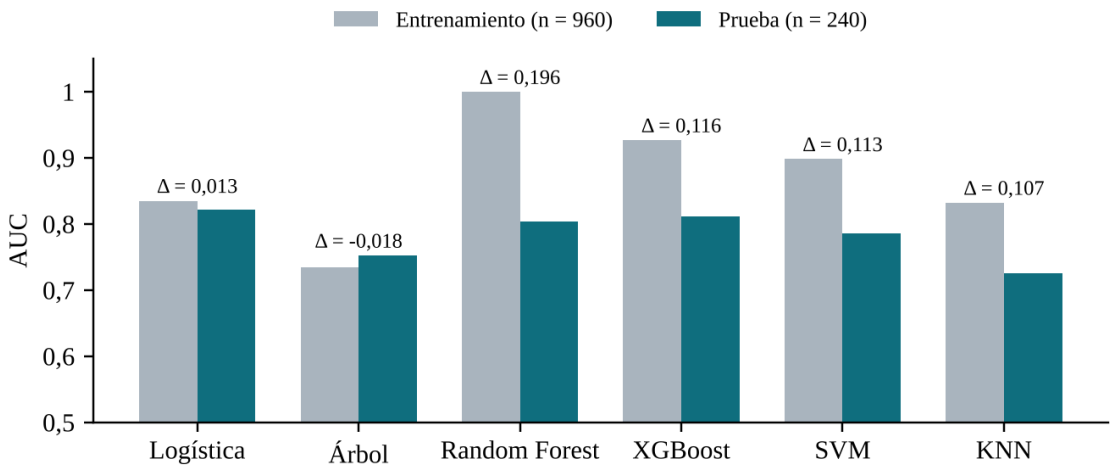
AUC en entrenamiento y prueba y brecha de generalización

Modelo	AUC entrenamiento	AUC prueba	Brecha	Accuracy entrenamiento	Accuracy prueba	Diagnóstico
Regresión logística	0,835	0,822	0,013	0,765	0,729	Sin sobreajuste
Árbol de decisión	0,734	0,752	−0,018	0,728	0,742	Subajuste
Random Forest	1,000	0,804	0,196	0,992	0,746	Memorización
XGBoost	0,927	0,811	0,116	0,842	0,708	Moderado
SVM	0,898	0,785	0,113	0,828	0,721	Moderado
KNN	0,832	0,725	0,107	0,765	0,679	Moderado*

Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). Tabla Sobreajuste: AUC entrenamiento vs. prueba del módulo 4. Brecha = AUC entrenamiento − AUC prueba. *En KNN la métrica de entrenamiento está inflada porque cada observación es su propio vecino.

Figura 11

AUC en entrenamiento y en prueba por modelo



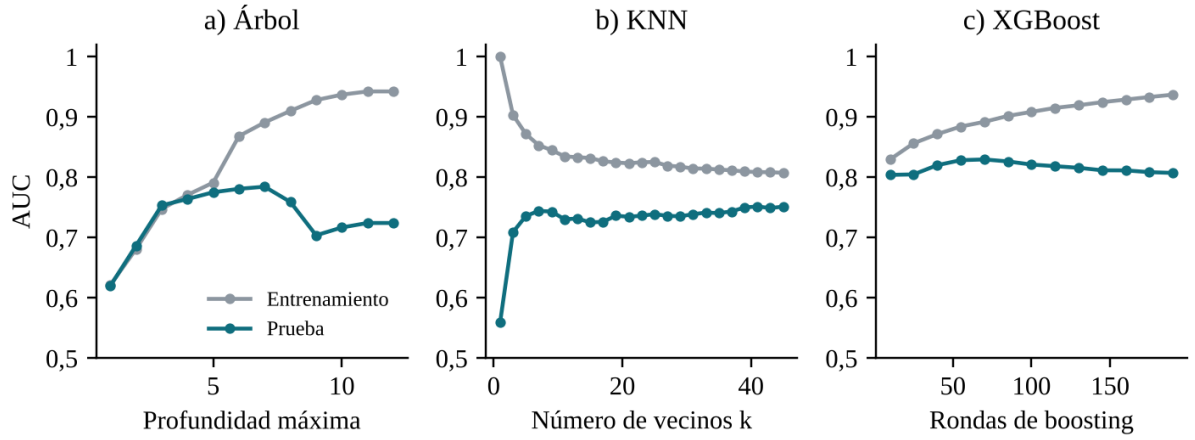
Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). Δ indica la brecha (entrenamiento − prueba).

La Tabla 19 y la Figura 11 distinguen tres situaciones. La regresión logística (brecha 0,013) generaliza sin pérdida apreciable, como corresponde a un modelo de baja varianza. El árbol con profundidad 4 presenta una brecha negativa (−0,018) y el AUC de entrenamiento más

bajo (0,734): es un caso de subajuste, en el que el sesgo del modelo, y no la varianza, limita el desempeño. Random Forest, XGBoost, SVM y KNN muestran brechas de entre 0,107 y 0,196, con el caso extremo de Random Forest, que memoriza el entrenamiento (AUC = 1,000). En ninguno de estos modelos el mayor ajuste en entrenamiento se tradujo en un AUC de prueba superior al de la regresión logística.

Figura 12

Curvas de complejidad del laboratorio de sobreajuste



Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). Módulo 7. a) Árbol con cp = 0,001 y minsplit = 10, profundidad de 1 a 12; b) KNN con k impar de 1 a 45; c) XGBoost con profundidad 3, η = 0,05 y de 10 a 190 rondas.

Las curvas de complejidad muestran el compromiso entre sesgo y varianza en los tres modelos con un hiperparámetro de complejidad claro. En el árbol, con profundidades de 1 a 4 los AUC de entrenamiento y prueba crecen juntos (de 0,62 a 0,76), lo que corresponde a la región de subajuste; a partir de la profundidad 5 el AUC de entrenamiento sigue aumentando hasta 0,943, mientras que el de prueba alcanza su máximo de 0,785 con profundidad 7 y luego desciende a valores entre 0,70 y 0,72. En KNN la relación se invierte porque la complejidad disminuye al aumentar *k*: con $k = 1$ el modelo memoriza (AUC de entrenamiento 1,000 y de prueba 0,560), y con *k* creciente las dos curvas convergen, con un máximo de prueba de 0,752 en $k = 41$. En XGBoost, el AUC de prueba crece de 0,804 con 10 rondas a 0,830 con 70 y desciende lentamente después, mientras la brecha aumenta de forma continua.

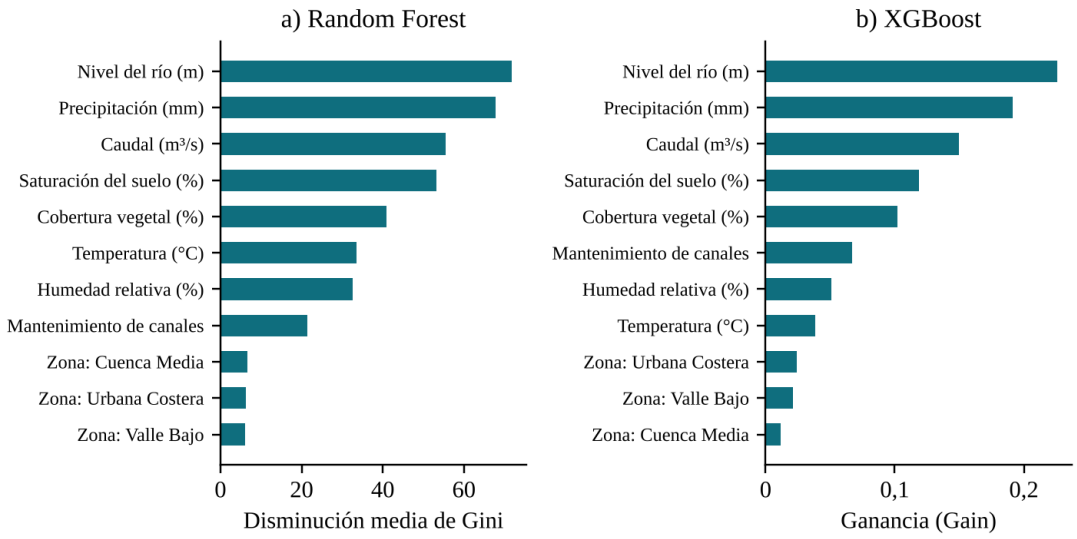
Estos resultados indican que las configuraciones por defecto no se encuentran en el punto óptimo de generalización: el árbol es demasiado simple, XGBoost utiliza más rondas de las necesarias y KNN emplea menos vecinos de los que maximizan el AUC de prueba. No obstante, estos óptimos se identificaron con el propio conjunto de prueba, por lo que su valor es ilustrativo; utilizarlos para seleccionar hiperparámetros y reportar después el desempeño en

ese mismo conjunto produciría estimaciones optimistas. Una selección válida requeriría validación cruzada sobre el entrenamiento.

4.17. Importancia de variables

Figura 13

Importancia de variables en Random Forest y XGBoost



Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). Panel a: disminución media del índice de Gini; panel b: ganancia relativa (la suma de ganancias es 1). Gráfico Importancia de un modelo del módulo 6.

Tabla 20

Importancia relativa de los predictores en los cuatro modelos interpretables (100 = variable más importante de cada modelo)

Variable	Logística |β|	Árbol (impureza)	Random Forest (Gini)	XGBoost (ganancia)
Nivel del río (m)	100	100	100	100
Precipitación (mm)	96	37	95	85
Caudal (m³/s)	71	49	77	66
Saturación del suelo (%)	62	29	74	53
Cobertura vegetal (%)	45	1	57	45
Mantenimiento de canales	48	1	30	30
Temperatura (°C)	13	2	47	17
Humedad relativa (%)	4	2	45	23
Zona: Urbana Costera	50	—	9	11
Zona: Valle Bajo	45	—	8	9
Zona: Cuenca Media	2	—	9	5

Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). Heatmap de importancia relativa del módulo 6. —: la variable no interviene en el modelo. La SVM y KNN no proporcionan una medida de importancia.

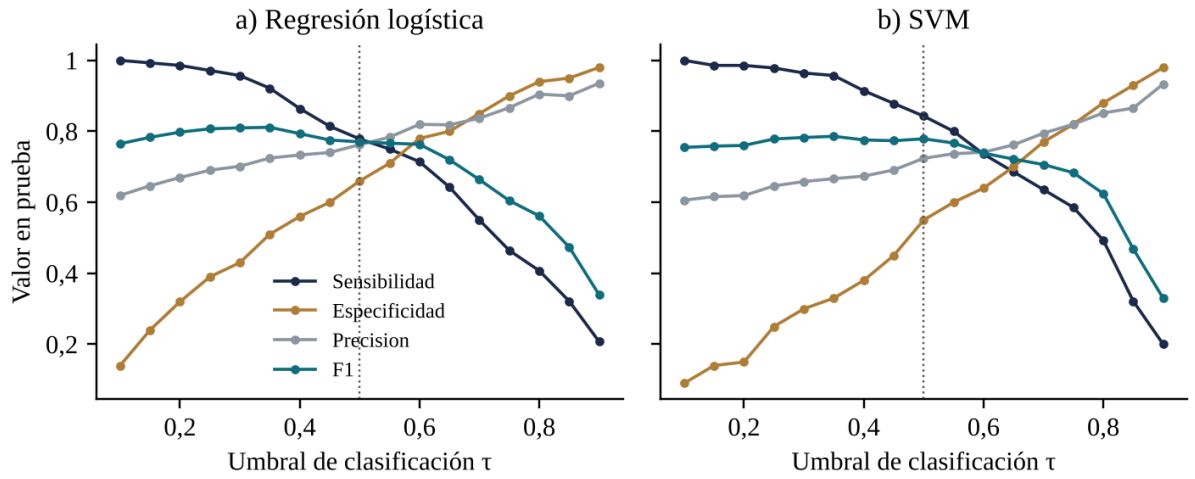
Los cuatro modelos interpretables coinciden en la jerarquía de los predictores. El nivel del río es la variable más importante en todos ellos, y la precipitación ocupa el segundo lugar en la logística (96), Random Forest (95) y XGBoost (85); en el árbol, el caudal la supera (49 frente a 37) porque interviene en la segunda partición. El caudal y la saturación del suelo completan el grupo de variables dominantes, con valores relativos de entre 29 y 77. Esta jerarquía coincide con la de los tamaños de efecto de la Tabla 5 y con los odds ratio de la Tabla 8, lo que da consistencia a la interpretación: la señal predictiva se concentra en cuatro variables hidrológicas.

Las diferencias entre medidas reflejan sus propiedades. Random Forest asigna importancias de Gini apreciables a la temperatura (47 en escala relativa) y a la humedad relativa (45), variables que no se asocian con la alerta (Tabla 5) y que la logística prácticamente descarta (13 y 4). Se trata de un sesgo conocido de la importancia de Gini, que favorece a las variables continuas con muchos puntos de corte posibles y no debe interpretarse como relevancia. La logística, en cambio, asigna importancia a la Zona Urbana Costera (50) y a Valle Bajo (45), que los modelos de árboles valoran poco (5 a 11) porque las variables binarias ofrecen un único punto de corte. En todos los casos, la importancia es predictiva y no causal: indica qué variables utiliza cada modelo para clasificar en estos datos, y en una base simulada refleja el mecanismo con que fueron generados, no relaciones físicas verificadas.

4.18. Evaluación del umbral de clasificación

Figura 14

Métricas en el conjunto de prueba según el umbral de clasificación



Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). Umbrales de 0,10 a 0,90 con incrementos de 0,05; la línea vertical marca τ = 0,5, valor por defecto del deslizador del módulo 5.

Tabla 21

Efecto del umbral sobre la sensibilidad, la especificidad y los errores en prueba

τ	Logística: Recall	Esp.	FN	FP	RF: Recall	Esp.	FN	FP
0,3	0,957	0,430	6	57	0,986	0,270	2	73
0,4	0,864	0,560	19	44	0,929	0,420	10	58
0,5	0,779	0,660	31	34	0,857	0,590	20	41
0,6	0,714	0,780	40	22	0,707	0,750	41	25
0,7	0,550	0,850	63	15	0,543	0,860	64	14

Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). FN: inundaciones omitidas (de 140); FP: falsas alarmas (de 100).

El umbral desplaza el punto de operación a lo largo de la curva ROC sin modificar el AUC. En la regresión logística, reducir τ de 0,5 a 0,3 eleva la sensibilidad de 0,779 a 0,957, reduce las inundaciones omitidas de 31 a 6 y aumenta las falsas alarmas de 34 a 57; elevar τ a 0,7 tiene el efecto contrario (63 omisiones y 15 falsas alarmas). Random Forest sigue el mismo patrón: con $\tau = 0{,}3$ omite 2 inundaciones a costa de 73 falsas alarmas. La exactitud de la logística varía poco entre $\tau = 0{,}3$ y $\tau = 0{,}6$ (entre 0,729 y 0,742), lo que indica que el umbral que maximiza la exactitud no es único ni especialmente informativo; la decisión debe basarse en los costos relativos de omitir una inundación y de emitir una falsa alarma.

La comparación entre modelos con distintos umbrales también matiza los resultados de la Tabla 15. Con $\tau = 0{,}4$, la logística alcanza una sensibilidad de 0,864 y una especificidad de 0,560, valores muy próximos a los de la SVM con $\tau = 0{,}5$ (0,843 y 0,550) y superiores a los de KNN (0,857 y 0,430). Parte de la ventaja en sensibilidad que exhiben Random Forest, KNN y SVM con $\tau = 0{,}5$ refleja, por tanto, su punto de operación y no una capacidad superior de detección: un modelo con mejor AUC puede igualar esa sensibilidad modificando el umbral, con un número igual o menor de falsas alarmas.

Tabla 22

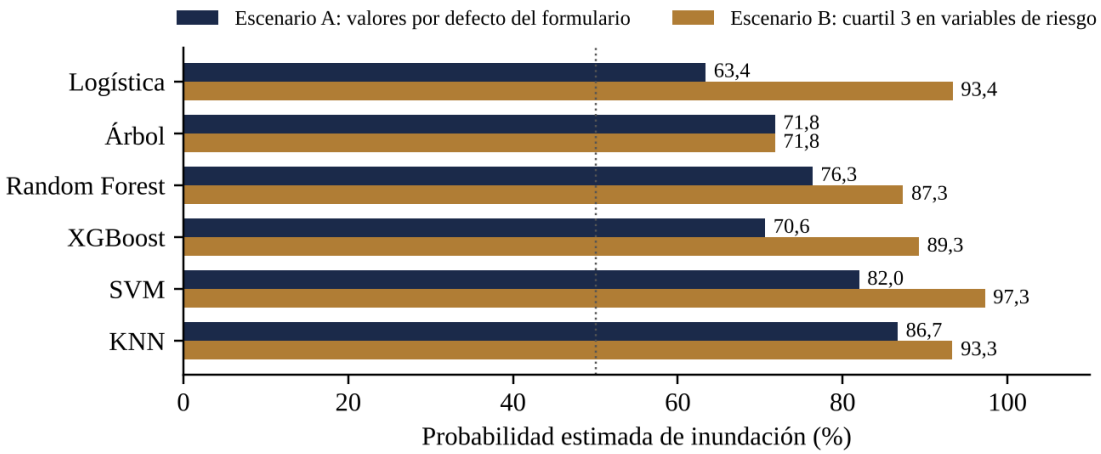
Valores de entrada de los escenarios de predicción

Variable	Escenario A (formulario por defecto)	Escenario B (riesgo elevado)
Zona hidrológica	Valle Bajo	Zona Urbana Costera
Precipitación (mm)	45,69	62,05
Caudal (m^3/s)	120,77	147,72
Nivel del río (m)	3,16	3,83
Saturación del suelo (%)	64,60	76,50
Cobertura vegetal (%)	39,05	39,05
Temperatura (°C)	21,95	21,95
Humedad relativa (%)	80,20	80,20
Mantenimiento de canales	2	2

Nota. Escenario A: valores que la aplicación precarga en el formulario de predicción individual (medianas y moda de la base). Escenario B: cuartil 3 de entrenamiento en las cuatro variables de mayor efecto y Zona Urbana Costera; calculado como análisis complementario.

Figura 15

Probabilidad estimada de inundación en los dos escenarios de predicción



Nota. Elaboración propia mediante la ejecución de app.R con datos_control_inundaciones.xlsx (parámetros por defecto, semilla 2024). La línea punteada marca el umbral $\tau = 0{,}5$.

El módulo de predicción transforma los valores introducidos con los mismos parámetros de imputación, codificación y escala del entrenamiento y aplica el modelo seleccionado. Con los valores precargados del formulario (escenario A) y la opción «Mejor modelo», que con el criterio por defecto (AUC) corresponde a la regresión logística, la probabilidad estimada es 63,4 %, por lo que con $\tau = 0{,}5$ la aplicación emite una alerta de inundación. Los otros modelos estiman entre 70,6 % (XGBoost) y 86,7 % (KNN). La dispersión de estimaciones para un mismo caso, de más de 23 puntos porcentuales, muestra que la probabilidad reportada depende del modelo y que solo la de un modelo con buena calidad probabilística debería comunicarse como riesgo. En el escenario B, con valores elevados de las variables de riesgo, las probabilidades aumentan a entre 87,3 % y 97,3 % en cinco modelos; el árbol mantiene 71,8 % porque ambos escenarios caen en la misma hoja, una limitación propia de las predicciones escalonadas.

5. Discusión

El resultado central del estudio es que el mejor modelo depende del criterio. Random Forest obtiene la mayor exactitud, F1 y MCC con el umbral convencional, mientras que la regresión logística obtiene el mayor AUC, la mayor especificidad y precisión y las probabilidades de mayor calidad. Esta divergencia tiene una explicación estadística: las métricas dependientes del umbral evalúan un único punto de operación, determinado por la

distribución de probabilidades de cada modelo y por la ponderación de clases, mientras que el AUC y las reglas de puntuación evalúan el ordenamiento y la magnitud de todas las probabilidades. Un modelo puede situar más casos del lado correcto de 0,5 y, sin embargo, ordenar peor los casos en el resto del rango, como ocurre con Random Forest y, de forma más acusada, con el árbol de decisión.

La competitividad de la regresión logística frente a modelos más flexibles es coherente con la estructura de los datos. Las cuatro variables que concentran la señal tienen efectos aproximadamente monótonos, los predictores son independientes entre sí y el análisis exploratorio no reveló patrones que requieran interacciones complejas. En esas condiciones, la capacidad de los métodos basados en árboles o núcleos para representar no linealidades no aporta información adicional y sí aporta varianza, como muestran sus brechas de generalización. A esto se suma un elemento que no puede ignorarse: el código de la aplicación incluye un generador de datos basado en un predictor lineal logístico. Aunque no puede verificarse que la base analizada proceda exactamente de esa función, si su mecanismo es similar, la regresión logística estaría correctamente especificada y su ventaja sería esperable. Los resultados, por tanto, no autorizan a generalizar que la logística supere a Random Forest o XGBoost en la predicción de inundaciones con datos reales, donde los umbrales físicos, las interacciones entre lluvia y saturación y la dependencia temporal favorecerían a los modelos flexibles.

En un sistema de alerta, el equilibrio entre sensibilidad y falsas alarmas es la decisión más relevante. Los resultados muestran que la sensibilidad elevada de Random Forest, KNN y la SVM con $\tau = 0,5$ se obtiene con 41 a 57 falsas alarmas por cada 100 casos normales, y que la regresión logística alcanza sensibilidades similares cuando se reduce el umbral. La comparación de modelos con un umbral común confunde, por tanto, dos aspectos distintos: la capacidad de discriminar y la posición elegida sobre la curva ROC. Para fines operativos, el procedimiento adecuado consiste en seleccionar el modelo por su capacidad discriminante y su calidad probabilística y, a continuación, fijar el umbral según una función de costos explícita o una restricción de sensibilidad mínima. Con esa lógica, un modelo con AUC alto y probabilidades confiables ofrece mayor flexibilidad que un modelo con alta exactitud en un único umbral.

La distinción entre desempeño observado y superioridad demostrada condiciona todas las conclusiones. Con 240 casos de prueba, la incertidumbre de la exactitud es de unos ±5,6 puntos porcentuales, y las diferencias entre los cuatro mejores modelos son de 1 a 4 puntos. Las

pruebas pareadas confirman esa lectura: ninguna diferencia de exactitud es significativa tras el ajuste por comparaciones múltiples, y en AUC solo se sustentan las diferencias de la logística frente a KNN y, de forma marginal, frente a la SVM. La validación cruzada aporta una segunda partición de los datos y coincide en que la logística discrimina mejor y en que el árbol con profundidad 4 es el más débil, pero altera el orden de los modelos intermedios. El ordenamiento de los seis modelos en la Tabla 15 describe esta partición concreta y no una jerarquía estable.

El diagnóstico de sobreajuste ofrece una lectura complementaria. Random Forest memoriza el entrenamiento sin que ello deteriore gravemente su desempeño fuera de la muestra, lo que confirma que la brecha en sí misma no es un criterio de selección; lo relevante es el desempeño en datos no vistos y su estabilidad. El árbol, en el extremo opuesto, sufre de sesgo y no de varianza, y el laboratorio indica que una profundidad de 6 o 7 mejoraría su AUC de prueba. En XGBoost y KNN los hiperparámetros por defecto se alejan del punto de mejor generalización. Estas observaciones sugieren que el ordenamiento de los modelos podría cambiar con una optimización de hiperparámetros, aunque las curvas de complejidad indican que los máximos alcanzables (0,785 en el árbol, 0,752 en KNN y 0,830 en XGBoost) no superarían con claridad a la regresión logística.

El estudio tiene limitaciones que delimitan su alcance. Los datos son simulados y carecen de la correlación entre variables hidrológicas, la estructura temporal y la heterogeneidad espacial de las observaciones reales, por lo que los resultados no pueden trasladarse a una cuenca concreta ni interpretarse como capacidad operativa de predicción. La evaluación se basa en una única partición de 240 casos, complementada con una validación cruzada de cinco pliegues sobre el entrenamiento. Los hiperparámetros no se optimizaron y los óptimos del laboratorio se leyeron sobre el conjunto de prueba. La imputación con medianas de toda la base introduce una fuga de información mínima, y el umbral de 0,5 no responde a un análisis de costos. Finalmente, las probabilidades de los modelos ponderados no corresponden a la prevalencia observada sin recalibración, y los valores *p* de la regresión logística ponderada son aproximados.

6. Conclusiones

1. La mayor exactitud en el conjunto de prueba correspondió a Random Forest (0,746; 179 de 240 casos), que también obtuvo el mayor F1 (0,797) y MCC (0,469) con $\tau = 0,5$. Su ventaja sobre el árbol (0,742) y la regresión logística (0,729) no es estadísticamente demostrable: la

prueba exacta de McNemar frente a la logística arroja $p = 0{,}597$ y el intervalo bootstrap de la diferencia (−2,9 a +6,3 puntos) incluye el cero.

2. La mayor capacidad discriminante correspondió a la regresión logística, con AUC de 0,822 (IC 95 %: 0,769–0,875) en prueba y 0,829 (DE = 0,045) en validación cruzada. Su diferencia con XGBoost (0,811) y Random Forest (0,804) no es significativa (DeLong $p = 0{,}417$ y 0,299), mientras que sí lo es frente a KNN ($p < 0{,}001$ con ajuste de Holm) y, en el límite, frente a la SVM ($p = 0{,}0495$).

3. Random Forest y KNN alcanzaron la mayor sensibilidad (0,857; 120 de 140 inundaciones), seguidos por la SVM (0,843). Esta sensibilidad se acompañó de las especificidades más bajas (0,590, 0,430 y 0,550; 41, 57 y 45 falsas alarmas), mientras que la logística obtuvo la mayor especificidad (0,660) y precisión (0,762). La ventaja en sensibilidad refleja en buena medida el punto de operación: con $\tau = 0{,}4$ la logística alcanza una sensibilidad de 0,864 con especificidad de 0,560.

4. La calidad de las probabilidades estimadas favorece a la regresión logística (Log Loss = 0,499; Brier = 0,168) y a XGBoost (0,510; 0,170), y penaliza a KNN (0,665; 0,209) y al árbol (0,568; 0,190), cuyas probabilidades son proporciones discretas. Ningún modelo ponderado puede considerarse calibrado sin recalibración, y las curvas por deciles, con 24 casos por punto, solo permiten una valoración descriptiva.

5. Los modelos más flexibles mostraron sobreajuste sin mejorar el AUC de prueba de la logística: Random Forest memorizó el entrenamiento (AUC 1,000 frente a 0,804; brecha 0,196) y XGBoost, la SVM y KNN presentaron brechas de 0,107 a 0,116. La logística generalizó sin pérdida (brecha 0,013) y el árbol con profundidad 4 mostró subajuste (AUC 0,734 en entrenamiento y 0,682 en validación cruzada). El laboratorio indicó óptimos de prueba de profundidad 7 en el árbol (0,785), k = 41 en KNN (0,752) y 70 rondas en XGBoost (0,830).

6. La señal predictiva se concentra en cuatro variables hidrológicas. El nivel del río (d = 0,656; OR = 2,38 por DE) y la precipitación (d = 0,631; OR = 2,31) son las más importantes en los cuatro modelos interpretables, seguidas por el caudal (OR = 1,85) y la saturación del suelo (OR = 1,71); la cobertura vegetal y el mantenimiento de canales se asocian con menor riesgo (OR = 0,67 y 0,66), y la temperatura y la humedad no aportan información. La importancia es predictiva y no causal.

7. No existe un modelo superior en todos los criterios. Para estimar probabilidades y ordenar el riesgo, la regresión logística es la opción mejor respaldada; para clasificar con el umbral

convencional maximizando aciertos, Random Forest obtiene los mejores valores observados; para disponer de reglas operativas explícitas, el árbol de decisión ofrece una exactitud comparable (0,742) con menor capacidad discriminante. En todos los casos, el umbral debe fijarse según el costo relativo de las omisiones y las falsas alarmas.

8. El alcance de estas conclusiones es metodológico. Los datos son simulados, presentan predictores independientes y probablemente un mecanismo generador lineal en el logit, lo que favorece a la regresión logística; la evaluación descansa en 240 casos de prueba y en hiperparámetros no optimizados. La transferencia de estos resultados a un sistema de alerta real requiere validación con registros hidrometeorológicos observados, esquemas de validación temporal o espacial y una definición explícita de costos.

7. Referencias bibliográficas

Benjamini, Y., & Hochberg, Y. (1995). Controlling the false discovery rate: A practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B (Methodological), 57*(1), 289–300. https://doi.org/10.1111/j.2517-6161.1995.tb02031.x

Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Breiman, L., Friedman, J. H., Olshen, R. A., & Stone, C. J. (1984). *Classification and regression trees*. Wadsworth.

Brier, G. W. (1950). Verification of forecasts expressed in terms of probability. *Monthly Weather Review, 78*(1), 1–3.

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). ACM. https://doi.org/10.1145/2939672.2939785

Chicco, D., & Jurman, G. (2020). The advantages of the Matthews correlation coefficient (MCC) over F1 score and accuracy in binary classification evaluation. *BMC Genomics, 21*, Artículo 6. https://doi.org/10.1186/s12864-019-6413-7

Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2.ª ed.). Lawrence Erlbaum Associates.

Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning, 20*(3), 273–297. https://doi.org/10.1007/BF00994018

Cover, T., & Hart, P. (1967). Nearest neighbor pattern classification. *IEEE Transactions on Information Theory, 13*(1), 21–27. https://doi.org/10.1109/TIT.1967.1053964

DeLong, E. R., DeLong, D. M., & Clarke-Pearson, D. L. (1988). Comparing the areas under two or more correlated receiver operating characteristic curves: A nonparametric approach. *Biometrics, 44*(3), 837–845. https://doi.org/10.2307/2531595

Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters, 27*(8), 861–874. https://doi.org/10.1016/j.patrec.2005.10.010

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2.ª ed.). Springer. https://doi.org/10.1007/978-0-387-84858-7

Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics, 6*(2), 65–70.

Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied logistic regression* (3.ª ed.). Wiley. https://doi.org/10.1002/9781118548387

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning: With applications in R* (2.ª ed.). Springer. https://doi.org/10.1007/978-1-0716-1418-1

Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. En *Proceedings of the 14th International Joint Conference on Artificial Intelligence* (Vol. 2, pp. 1137–1143). Morgan Kaufmann.

Kuhn, M., & Johnson, K. (2013). *Applied predictive modeling*. Springer. https://doi.org/10.1007/978-1-4614-6849-3

Liaw, A., & Wiener, M. (2002). Classification and regression by randomForest. *R News, 2*(3), 18–22.

McNemar, Q. (1947). Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika, 12*(2), 153–157. https://doi.org/10.1007/BF02295996

Platt, J. C. (1999). Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. En A. J. Smola, P. Bartlett, B. Schölkopf, & D. Schuurmans (Eds.), *Advances in large margin classifiers* (pp. 61–74). MIT Press.

R Core Team. (2024). *R: A language and environment for statistical computing*. R Foundation for Statistical Computing. https://www.R-project.org/

Robin, X., Turck, N., Hainard, A., Tiberti, N., Lisacek, F., Sanchez, J.-C., & Müller, M. (2011). pROC: An open-source package for R and S+ to analyze and compare ROC curves. *BMC Bioinformatics, 12*, Artículo 77. https://doi.org/10.1186/1471-2105-12-77

Strobl, C., Boulesteix, A.-L., Zeileis, A., & Hothorn, T. (2007). Bias in random forest variable importance measures: Illustrations, sources and a solution. *BMC Bioinformatics, 8*, Artículo 25. https://doi.org/10.1186/1471-2105-8-25

Welch, B. L. (1947). The generalization of «Student's» problem when several different population variances are involved. *Biometrika, 34*(1–2), 28–35. https://doi.org/10.1093/biomet/34.1-2.28